

В данной работе предлагается провести статистическую обработку заданной выборки, извлеченной из генеральной совокупности некоторой случайной величины X , закон распределения и числовые характеристики которой не известны. Статистическую обработку следует провести в три этапа.

На **первом этапе** нужно провести первичную обработку статистических данных, т.е.

- 1) составить группированный ряд распределения;
- 2) построить эмпирическую функцию распределения, ее график и кумуляту;
- 3) вычислить плотности относительных частот, построить гистограмму и полигон относительных частот;
- 4) получить точечные статистические оценки для математического ожидания, дисперсии, среднего квадратичного отклонения и медианы;
- 5) методом моментов получить точечные оценки для эксцесса и асимметрии;
- 6) построив доверительный интервал для эксцесса и асимметрии, проверить гипотезу о нормальном распределении генеральной совокупности X .

На **втором этапе** нужно проверить гипотезу о нормальном распределении генеральной совокупности X по критерию Пирсона. Для этого

- 1) выдвинуть основную и конкурирующую гипотезы о гипотетическом законе распределения;
- 2) вычислить теоретические частоты, используя функцию распределения гипотетического закона;
- 3) построить на одном рисунке полигон относительных частот и теоретическую кривую, сравнив эти кривые между собой;
- 4) выбрать статистический закон распределения (в данной работе критерий Пирсона) и вычислить наблюдаемое значение критерия;

- 5) задав уровень значимости и определив число степеней свободы, найти критическое значение критерия принять основную или конкурирующую гипотезу.

Если генеральная совокупность распределена по нормальному закону, то **третьем этапе** построить доверительные интервалы для математического ожидания и дисперсии. Если гипотеза о нормальном распределении на втором этапе отвергнута, то для построения доверительных интервалов для математического ожидания и дисперсии можно использовать те же формулы, что и для нормального распределения, если объем выборки достаточно велик (≥ 50). В этом случае доверительные интервалы будут найдены приближенно.

В конце работы помещен расчетный пример и приведен список вопросов, которые Вы должны разобрать самостоятельно по лекциям и компендиуму по теме 10.2.

I этап. Первичная обработка статистических данных

1. Построение группированного статистического ряда

- 1) В выборке найти наименьший $x_{\min}$ и наибольший $x_{\max}$ элементы.
2) Найти объем выборки n . Найти размах выборки по формуле:

$$R_B = x_{\max} - x_{\min}.$$

- 3) Для заданного объема выборки n по формуле Стёрджеса найти оптимальное число интервалов l :

$$l = [1 + 3,32 \cdot \lg n].$$

- 4) Найти длину каждого интервала h :

$$h = \frac{R_B}{l}.$$

- 5) Найти границы полуоткрытых интервалов группированного статистического ряда по формулам:

$$I_i = [x_{i-1}, x_i),$$

где $x_0 = x_{\min}$, $x_i = x_0 + i \cdot h$, $i = 1, \dots, l-1$, $x_l = x_{\max}$.

6) Выписать полученные полуоткрытые интервалы

$$I_1 = [x_0; x_1);$$

$$I_2 = [x_1; x_2);$$

$$I_3 = [x_2; x_3);$$

.....

$$I_l = [x_{l-1}; x_l).$$

7) Вычислить абсолютные частоты n_i – число наблюдений в выборке, попавших в интервал I_i . Для удобства подсчета абсолютных частот, выборку следует упорядочить, т.е. составить вариационный ряд

$$x_1 \leq x_2 \leq x_3 \leq \dots \leq x_{n-1} \leq x_n.$$

8) Вычислить относительные частоты по формуле:

$$p_i^* = \frac{n_i}{n}.$$

9) Записать группированный статистический ряд:

Таблица 1

I_i	I_1	I_2		I_l	Σ
n_i	n_1	n_2		n_l	n
p_i^*	p_1^*	p_2^*		p_l^*	1

2. Построение эмпирической функции распределения

1) Вычислить середины интервалов группированного ряда по формулам:

$$\bar{x}_i = \frac{x_{i-1} + x_i}{2}, \quad i = 1, 2, \dots, l.$$

2) Вычислить накопленные относительные частоты z_i по формулам:

$$z_1 = p_1^*; \quad z_2 = p_1^* + p_2^*; \dots; \quad z_i = \sum_{k=1}^i p_k^*, \quad i = 3, \dots, l-1; \quad z_l = 1.$$

3) Записать дискретный статистический ряд для середин интервалов, относительных частот и накопленных частот

$y = 0$, при $x \leq x_1$ и

$y = 1$, при $x > x_l$.

На рисунке 2 построена кумюлята для графика функции распределения, показанной на рисунке 1.




Рис. 2.

3. Эмпирическая плотность относительных частот.

Гистограмма и полигон относительных частот

1) Вычислить плотности относительных частот $f_n^*(x)$ по формуле:

$$f_i^*(x) = \frac{p_i^*}{h},$$

где: p_i^* — относительная частота попадания случайной величины в интервал I_i ; h — длина интервала I_i .

2) Внести в таблицу середины интервалов и плотности частот:

Таблица 3

$\bar{x}_i$	$\bar{x}_1$	$\bar{x}_2$		$\bar{x}_l$
$f_i^*(x)$	$f_1^*(x)$	$f_2^*(x)$		$f_l^*(x)$

3) Записать аналитическое выражение для эмпирической плотности относительных частот $f_n^*(x)$ на каждом из интервалов I_i , при $i = 1, 2, \dots, l$.

4) Построить гистограмму плотностей относительных частот. Пример гистограммы для статистического ряда с четырьмя интервалами, показан на рис. 3.



7




Рис. 4.

6) По виду гипотетической кривой сделать предварительное предположение о распределении генеральной совокупности, из которой извлечена выборка.

4. Получение точечных статистических оценок

1) Вычислите выборочное среднее $\bar{x}$ по формуле

$$\bar{x} = \sum_{i=1}^l \bar{x}_i p_i^*,$$

где $\bar{x}_i$ – порядковые статистики, p_i^* – относительные частоты.

2) Вычислите выборочную дисперсию s^2 по формуле

$$s^2 = \sum_{i=1}^l \bar{x}_i^2 p_i^* - \bar{x}^2,$$

где $\bar{x}_i$ – порядковые статистики, p_i^* – относительные частоты, $\bar{x}$ – выборочное среднее.

3. Вычислите исправленную выборочную дисперсию $\bar{s}^2$ и исправленное среднее квадратичное отклонение $\bar{s}$.

$$\bar{s}^2 = \frac{n}{n-1} s^2, \quad \bar{s} = \sqrt{\bar{s}^2},$$

где s^2 – выборочная дисперсия, n – объем выборки.

4. Вычислите выборочную медиану μ^* по формуле

$$\mu^* = \begin{cases} \bar{x}_{m+1}, & n = 2m + 1 \\ \frac{1}{2}(\bar{x}_m + \bar{x}_{m+1}), & n = 2m \end{cases},$$

где $\bar{x}_i$ – порядковые статистики, n – объем выборки.

5. Вычислите выборочную асимметрию A^* по формуле

$$A^* = \frac{1}{\bar{s}^3} \sum_{i=1}^l (\bar{x}_i - \bar{x})^3 p_i^*,$$

где $\bar{x}_i$ – порядковые статистики, $\bar{s}$ – среднее квадратичное отклонение, p_i^* – относительные частоты, $\bar{x}$ – выборочное среднее.

6. Вычислите выборочный эксцесс E^* по формуле

$$E^* = \frac{1}{\bar{s}^4} \sum_{i=1}^l (\bar{x}_i - \bar{x})^4 p_i^* - 3,$$

где $\bar{x}_i$ – порядковые статистики, $\bar{s}$ – среднее квадратичное отклонение, p_i^* – относительные частоты, $\bar{x}$ – выборочное среднее.

ЗАМЕЧАНИЕ

Выборочные эксцесс и асимметрию можно вычислять, используя метод моментов, т.е. сначала вычислить моменты третьего M_3^* и четвертого M_4^* порядка

$$M_3^* = \sum_{i=1}^l \bar{x}_i^3 \cdot p_i^*, \quad M_4^* = \sum_{i=1}^l \bar{x}_i^4 \cdot p_i^*,$$

а затем использовать формулы

$$A^* = \frac{1}{\bar{s}^3} \left(M_3^* - 3M_1^* M_2^* + 2(M_1^*)^3 \right),$$

$$E^* = \frac{1}{\bar{s}^4} \left(M_4^* - 4M_1^* M_3^* + 6(M_1^*)^2 M_2^* - 3(M_1^*)^4 \right) - 3,$$

в которых выборочными моментами первого и второго порядка являются среднее выборочное и исправленная выборочная дисперсия, т.е. $M_1^* = \bar{x}$, $M_2^* = \bar{s}^2$.

II этап. Проверка гипотезы о нормальном законе распределения генеральной совокупности по

величине асимметрии и эксцесса. Построение теоретической кривой

1) На основании анализа формы полигона и гистограммы выдвигается основная гипотеза H_0 о виде распределения генеральной совокупности X . В данной работе гипотетическим распределением будет нормальный закон.

2) Альтернативная гипотеза H_1 будет заключаться в том, что основная гипотеза H_0 не выполнена.

3) Вычислите средние квадратичные отклонения выборочной асимметрии A^* и выборочного эксцесса E^* по формулам

$$\sigma_{A^*} = \sqrt{\frac{6(n-1)}{(n+1)(n+3)}},$$
$$\sigma_{E^*} = \sqrt{\frac{24n(n-2)(n-3)}{(n-1)^2(n+3)(n+5)}}.$$

4) Проверьте, не выходят ли значения выборочной асимметрии A^* и выборочного эксцесса E^* за пределы интервалов $(-2\sigma_{A^*}; 2\sigma_{A^*})$ и $(-2\sigma_{E^*}; 2\sigma_{E^*})$.

5) Если $A^* \in (-2\sigma_{A^*}; 2\sigma_{A^*})$ и $E^* \in (-2\sigma_{E^*}; 2\sigma_{E^*})$, то нет оснований отвергнуть основную гипотезу. Если значения выборочной асимметрии и выборочного эксцесса не попадают в эти интервалы, то гипотеза о нормальном распределении отвергается и принимается альтернативная гипотеза.

6) Если нет оснований отвергнуть основную гипотезу, то постройте теоретическую кривую – кривую плотности нормального распределения. Ординаты этой кривой определяются формулами

$$f(x_i) = \frac{1}{\bar{s}\sqrt{2\pi}} e^{-\frac{(x_i - \bar{x})^2}{2\bar{s}^2}}, \text{ или } f(x_i) = \frac{1}{\bar{s}} \varphi(v_i),$$

$$\text{где: } v_i = \frac{x_i - \bar{x}}{\bar{s}},$$

x_i – граничная точка i – го интервала группированного ряда,

$\bar{x}$ – выборочное среднее,
 $\bar{s}$ – исправленная выборочная дисперсия,

значения функции $\varphi(v_i) = \frac{1}{\sqrt{2\pi}} e^{-\frac{v_i^2}{2}}$ определите из таблицы (см. Приложение).

III этап. Проверка гипотезы о нормальном законе распределения генеральной совокупности по критерию Пирсона

3) Прежде чем использовать критерий Пирсона выясните, в каждом ли интервале ряда количество наблюдений больше пяти. Если в каком-то интервале это не так, то его объединяют с одним из соседних интервалов. При этом количество интервалов l уменьшается, а абсолютные частоты объединенных интервалов складываются.

4) Вычислите p_i – вероятности попадания случайной величины X в интервал $I_i = [x_{i-1}, x_i)$.

$$p_i = P\{x_{i-1} \leq X \leq x_i\} = F(x_i) - F(x_{i-1}), \quad i = 1, 2, \dots, l.$$

где $F(x)$ – гипотетическая функция распределения.

Если основная гипотеза H_0 : случайная величина X распределена по нормальному закону, то вероятности p_i определяются по формулам:

$$p_i = P\{x_{i-1} \leq X \leq x_i\} = \Phi\left(\frac{x_i - \bar{x}}{\bar{s}}\right) - \Phi\left(\frac{x_{i-1} - \bar{x}}{\bar{s}}\right), \quad i = 1, 2, \dots, l.$$

где $\bar{x}$ – среднее выборочное, $\bar{s}$ – исправленное среднее квадратичное отклонение, $\Phi(x)$ – функция Лапласа, значения которой находятся из таблицы (л.1 приложение 2).

5) Вычислите теоретические частоты по формулам:

$$p'_i = np_i, \quad i = 1, 2, \dots, l.$$

6) Вычислите статистику $\chi^2_{набл}$ по формуле

$$\chi^2_{набл} = \sum_{i=1}^l \frac{(n_i - p'_i)^2}{p'_i},$$

где n_i – абсолютные частоты, p'_i – теоретические частоты, l – количество интервалов интервального ряда.

7) Все вычисления внесите в таблицу 4.

Таблица 4

№	$[x_{i-1}, x_i)$	n_i	p_i	p'_i	$\frac{(n_i - p'_i)^2}{p'_i}$
1	$[x_0, x_1)$	n_1	p_1	p'_1	$(n_1 - p'_1)^2$
2	$[x_1, x_2)$	n_2	p_2	p'_2	$(n_2 - p'_2)^2$
...	...	...	...	...	...
l	$[x_{l-1}, x_l)$	n_l	p_l	p'_l	$(n_l - p'_l)^2$
Σ	—	$\Sigma = n$	$\Sigma = 1$	$\Sigma = n$	$\chi^2_{набл}$

8) Определите число степеней свободы m по формуле

$$m = l_1 - r - 1,$$

где l_1 – новое число интервалов; r – число оцениваемых параметров. Если проверяется гипотеза о нормальном распределении, то число оцениваемых параметров два: математическое ожидание a и среднее квадратичное отклонение σ .

9) По заданному значению уровня значимости α и по вычисленному числу степеней свободы m из таблицы распределения χ^2 (л.1, приложение 5) определяют границу критической области $\chi^2_{кр}$.

10) Гипотеза о выбранном теоретическом законе распределения случайной величины X принимается, если $\chi^2_{набл}$ попадает в область принятия гипотезы, т.е. при выполнении условия:

$$\chi^2_{набл} \leq \chi^2_{кр}.$$

Если $\chi_{набл}^2 > \chi_{кр}^2$, то гипотеза отвергается и принимается альтернативная гипотеза, т.е. распределение случайной величины X не совпадает с гипотетическим распределением.

IV этап. Интервальное оценивание параметров распределения нормально распределенной генеральной совокупности

1) Задайте доверительную вероятность $\beta = 0,92 \div 0,98$ и вычислите уровень значимости $\alpha = 1 - \beta$.

2) По таблице квантилей распределения Стьюдента (л.1, приложение 3) определите t_β (квантиль уровня β) в зависимости от доверительной вероятности β (или уровня значимости α) и от числа степеней свободы $m = l - 1$ (l – число интервалов статистического ряда).

3) Вычислите значение ε по формуле

$$\varepsilon = t_\beta \frac{\bar{s}}{\sqrt{m}}.$$

4) Запишите доверительный интервал для математического ожидания a нормального распределения

$$(\bar{x} - \varepsilon, \bar{x} + \varepsilon) \text{ или } \left(\bar{x} - \frac{\bar{s}}{\sqrt{m}} t_\beta; \bar{x} + \frac{\bar{s}}{\sqrt{m}} t_\beta \right).$$

где $\bar{x}$ – выборочное среднее, $\bar{s}$ – исправленное среднее квадратичное отклонение, m – число степеней свободы, t_β – найденный по таблице квантиль.

5) Найдите по таблице квантилей распределения χ_n^2 для $m = l - 1$, $\alpha_1 = \frac{1-\beta}{2}$ и $\alpha_2 = \frac{1+\beta}{2}$ квантили

$$\chi_1^2 = \chi_{\alpha_1, m}^2 \text{ и } \chi_2^2 = \chi_{\alpha_2, m}^2.$$

6) Запишите доверительный интервал для параметра σ – среднего квадратичного отклонения нормального распределения