

1. Основы математической статистики

Главной задачей математической статистики является разработка методов, позволяющих на основании ограниченного числа наблюдений над случайной величиной, сделать обоснованные заключения о законе ее распределения и числовых характеристиках.

1.1. Первичная обработка статистических данных

1.1.1. Генеральная совокупность и выборка

Пусть в результате случайного эксперимента наблюдаются значения случайной величины X с функцией распределения $F(x)$, а x_1 – реализация эксперимента (в эксперименте имело место событие $\{X = x_1\}$).

Если провести n экспериментов, то в результате получим n значений измеряемой случайной величины X , которые мы обозначим $x_1, x_2, \dots, x_n$ или $\{x_i\}_{i=1}^n$.

Определение 1.1.1

Генеральной совокупностью в статистике называют множество всех возможных значений случайной величины X . Случайную величину X называют *генеральной случайной величиной*. Иногда случайную величину X называют также генеральной совокупностью.

Случайная величина X может быть дискретной или непрерывной, принимать конечное или бесконечное множество значений.

Соответственно и генеральная совокупность может представлять собой конечное или бесконечное множество, дискретное или непрерывное.

Определение 1.1.2

Последовательность наблюдений $x_1, x_2, \dots, x_n$ случайной величины X , полученных в результате проведения n независимых экспериментов, называется *выборкой объема n* из генеральной совокупности X с функцией распределения $F(x)$.

Числа $x_1, x_2, \dots, x_n$ называются *наблюдениями* или *выборочными значениями* случайной величины.

О самой случайной величине X может быть ничего не известно или, например, известен закон ее распределения, но не известны параметры распределения. Поэтому важно уметь решать задачи математической статистики только на основе полученной выборки.

ЗАМЕЧАНИЕ

Выборку $x_1, x_2, \dots, x_n$ можно рассматривать как результат одновременного наблюдения n независимых одинаково распределенных случайных величин $X_1, X_2, \dots, X_n$.

Процесс получения независимых наблюдений из одной и той же генеральной совокупности называется простым случайным выбором.

Простой случайный выбор реализуется в эксперименте, в котором выбор происходит с возвращениями. Например, в урне два шара с номерами 1 и 2. Вынимается шар, фиксируется его номер, и шар возвращается в урну.

Для того, чтобы на основе выборки делать выводы о случайной величине X , объем выборки n должен быть достаточно большим, то есть выборка должна быть *представительной* (репрезентативной).

Для репрезентативности выборки необходимо также, чтобы она была случайной, т.е. чтобы каждый элемент генеральной совокупности в эту выборку попал с одинаковой вероятностью.

Таким образом, к случайному эксперименту предъявляются следующие требования:

- случайность;
- независимость;
- достаточно большой объем полученной выборки.

Определение 1.1.3

Пусть из генеральной совокупности извлекается выборка $x_1, x_2, \dots, x_n$. Если выборочные значения расположить в порядке возрастания, то полученная упорядоченная выборка

$$x_1^*, x_2^*, \dots, x_n^*, \text{ где } x_1^* \leq x_2^* \leq \dots \leq x_n^*$$

называется вариационным рядом.

Число $x_n^* - x_1^*$ называется *размахом* выборки, а отрезок $[x_1^*, x_n^*]$ - *диапазоном* выборки.

Определение 1.1.4

Выборочной случайной величиной X^* называют случайную величину, которая принимает значения $x_1^*, x_2^*, \dots, x_n^*$ с вероятностью $\frac{1}{n}$ каждое.

ЗАМЕЧАНИЕ 1

Определенная таким образом выборочная случайная величина X^* является дискретной.

ЗАМЕЧАНИЕ 2

Это определение корректно, так как сумма вероятностей равна в данном случае 1.

Определение 1.1.5

Статистикой t называется функция наблюдений $t = t(x_1, x_2, \dots, x_n)$ с множеством значений $t \in R$.

Если значения $t \in R^n$, то статистика называется *векторной*.

Пример 5.1.1

Функция $\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \sum_{i=1}^n x_i$, построенная по выборке $x_1, x_2, \dots, x_n$ из генеральной

совокупности X является статистикой. Эту статистику называют *средним выборочным значением*.

Пример 1.1.2

Вариационный ряд $x_1^* \leq x_2^* \leq \dots \leq x_n^*$ является статистикой. Все значения x_i^* также являются статистиками. Их называют *порядковыми статистиками*.

1.1.2. Статистический ряд распределения. Полигон частот

Пусть случайная величина X имеет дискретный закон распределения, из генеральной совокупности извлечена выборка $x_1, x_2, \dots, x_n$ и по ней построен вариационный ряд $x_1^* \leq x_2^* \leq \dots \leq x_n^*$. Если в вариационном ряду значение x_1^* встречается n_1 раз, значение x_2^* встречается n_2 раз, ..., значение x_k^* встречается n_k раз, то, очевидно, что общий объем выборки n определяется суммой

$$n = \sum_{i=1}^k n_i.$$

Определение 1.1.6

Числа n_i называются *частотами* или *абсолютными частотами*, соответствующими выборочным значениям x_i^* .

Определение 1.1.7

Числа w_i , вычисленные по формуле

$$w_i = n_i \cdot \frac{1}{n}, \quad (1.1.1)$$

называются *относительными частотами*:

Относительные частоты связаны зависимостью

$$\sum_{i=1}^k w_i = 1.$$

Определение 1.1.8

Статистическим рядом распределения выборочной случайной величины X^* называется таблица, в которой приведены различные наблюдения $x_1^*, x_2^*, \dots, x_k^*$ и соответствующие им абсолютные частоты n_i и относительные частоты w_i .

Пример 1.1.3

Случайная величина X представляет собой оценку, полученную на экзамене студентами одной академической группы. Выписанные оценки в порядке их выставления представляют собой случайную выборку:

4;4;5;3;4;5;4;3;3;5;4;4;2;3;4;2;3;4;4;3;3;2;2.

По данной выборке объема $n = 25$ можно построить вариационный ряд:

2;2;2;2;3;3;3;3;3;3;3;3;4;4;4;4;4;4;4;4;5;5;5.

Выписывая в таблицу различные порядковые статистики

$$x_1^* = 2, \quad x_2^* = 3, \quad x_3^* = 4, \quad x_4^* = 5,$$

соответствующие им абсолютные частоты n_i

$$n_1 = 4, \quad n_2 = 8, \quad n_3 = 10, \quad n_4 = 5,$$

а также относительные частоты $w_i = \frac{n_i}{n}$

$$w_1 = \frac{4}{25} = 0,16, \quad w_2 = \frac{8}{25} = 0,32, \quad w_3 = \frac{10}{25} = 0,4, \quad w_4 = \frac{5}{25} = 0,12,$$

получим статистический ряд распределения.

Статистический ряд распределения

Таблица 1.1.1

x_i^*	2	3	4	5	Σ
n_i	4	8	10	3	25
w_i^*	0,16	0,32	0,4	0,12	1

ЗАМЕЧАНИЕ 1

Последний столбец в статистическом ряде распределения предназначен для контроля полученных вычислений.

ЗАМЕЧАНИЕ 2

Составленный таким образом статистический ряд распределения часто называют дискретным в отличие от интервального, о котором речь пойдет далее. Дискретный ряд распределения в статистике используется, если есть веские основания предполагать, что генеральная совокупность имеет дискретный закон распределения и объем выборки, полученной в результате эксперимента не велик.

Геометрическим представлением ряда распределения является *полигон частот* или *полигон относительных частот*.

Определение 1.1.9

Полигоном частот называется ломаная, отрезки которой соединяют точки с координатами (x_i^*, n_i) , где x_i^* - порядковые статистики ряда, а n_i соответствующие абсолютные частоты. На рисунке 1.1.1.а изображен полигон частот примера 1.1.3.

Если вместо абсолютных частот n_i на оси ординат откладывать относительные частоты w_i , то получим *полигон относительных частот* (рис. 1.1.1.b).




Рис. 1.1.1.a.




Рис. 1.1.1.b.

5.1.3. Эмпирическая функция распределения

Пусть $x_1, x_2, \dots, x_n$ - n независимых наблюдений над случайной величиной X с неизвестной функцией распределения $F(x) = P\{X < x\}$. Для оценки неизвестной функции распределения вводится понятие *эмпирической функции распределения*.

Определение 1.1.10

Эмпирической функцией распределения выборочной случайной величины X^* называется функция, значение которой при каждом x определяется формулой:

$$F_n^*(x) = P\{X^* < x\}. \quad (1.1.2)$$

$F_n^*(x)$ – это функция распределения дискретной случайной величины X^* . Получить эмпирическую функцию распределения можно, построив по выборке $x_1, x_2, \dots, x_n$ статистический ряд $x_1^* \leq x_2^* \leq \dots \leq x_k^*$. Тогда

$$F_n^*(x) = \begin{cases} 0, & x \leq x_1^* \\ \sum_{i: x_i^* < x} w_i, & x_1^* < x < x_k^* \\ 1, & x > x_k^* \end{cases} \quad (1.1.3)$$

Следовательно, эмпирическая функция распределения является кусочно-постоянной. Ее график – ступенчатая линия со скачками в точках x_i^* , равными отношению $\frac{n_i}{n}$, где n_i – абсолютные частоты, соответствующие порядковым статистикам x_i^* , а n – объем выборки.

Пусть выборка получена в результате n независимых испытаний. Поскольку дискретная выборочная случайная величина X^* принимает значения x_i с вероятностями $p_i = \frac{1}{n}$, то

$F_n^*(x) = \frac{m}{n}$, где m – число наблюдений в выборке, меньших x . Следовательно, $F_n^*(x)$ представляет собой частоту события $\{X^* < x\}$. По закону больших чисел в форме Бернулли частота события стремится по вероятности к вероятности этого события, т.е. к $P\{X < x\} = F(x)$.

$$F_n^*(x) \xrightarrow[n \rightarrow \infty]{p.} F(x) \text{ при любом } x.$$

Для получения эмпирической функции распределения в статистический ряд распределения добавляют строки, в которых вычисляют так называемые *накопленные частоты* $\sum_{j < i} n_j$ и *накопленные относительные частоты* $\sum_{j < i} w_j$.

Пример 1.1.4

Рассмотрим ряд распределения в примере 1.1.3.

Таблица 1.1.2

x_i^*	2	3	4	5	
n_i	4	8	10	3	25
w_i	0,16	0,32	0,4	0,12	1
$\sum_{j<i} n_j$	4	12	22	25	
$\sum_{j<i} w_j$	0,16	0,48	0,88	1	

По значениям накопленных относительных частот $\sum_{j<i} w_j$ в таблице 1.1.2 можно построить эмпирическую функцию распределения $F_n^*(x)$ и ее график (рис. 1.1.2).




Рис. 1.1.2.

1.1.4. Выборочные характеристики

Выборочными характеристиками называются моменты выборочной случайной величины X^* из генеральной совокупности X .

Основными выборочными характеристиками являются: выборочное среднее, выборочная дисперсия и выборочное среднее квадратичное отклонение.

Выборочное среднее

Выборочным средним $\bar{x}$ называется среднее арифметическое всех значений выборки, т.е.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1.1.4)$$

Если построен статистический ряд распределения и x_i^* ($i=1,2,\dots,k$) – порядковые статистики, то для выборочного среднего справедливы формулы

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k n_i x_i^* \quad \text{и} \quad \bar{\tilde{o}} = \sum_{i=1}^k w_i x_i^*, \quad (1.1.5)$$

где n – объем выборки, n_i – абсолютные частоты, w_i – относительные частоты,

$$n_1 + n_2 + \dots + n_k = n, \quad \sum_{i=1}^k w_i = 1.$$

Выборочное среднее является математическим ожиданием выборочной случайной величины X^* , т.е. $\bar{x} = M[X^*]$.

Выборочная дисперсия

Выборочная дисперсия обозначается s^2 и определяется формулой

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \quad (1.1.6)$$

Если построен статистический ряд распределения и x_i^* ($i=1,2,\dots,k$) – порядковые статистики, то выборочную дисперсию можно определить по следующим формулам:

$$s^2 = \frac{1}{n} \sum_{i=1}^k n_i (x_i^* - \bar{x})^2, \quad s^2 = \sum_{i=1}^k w_i (x_i^* - \bar{x})^2, \quad (1.1.7)$$

где n – объем выборки, n_i – абсолютные частоты, w_i – относительные частоты, $n_1 + n_2 + \dots + n_k = n$, $\sum_{i=1}^k w_i = 1$.

Выборочную дисперсию можно вычислить, пользуясь ее свойствами.

$$\begin{aligned} s^2 &= \sum_{i=1}^k w_i (x_i^* - \bar{x})^2 = \sum_{i=1}^k w_i (x_i^*)^2 - 2\bar{x} \sum_{i=1}^k w_i x_i^* + \bar{x}^2 \sum_{i=1}^k w_i = \\ &= \sum_{i=1}^k w_i (x_i^*)^2 - 2\bar{x}^2 + \bar{x}^2 = \sum_{i=1}^k w_i (x_i^*)^2 - \bar{x}^2, \text{ т.е.} \\ s^2 &= \overline{x^2} - \bar{x}^2. \end{aligned} \quad (1.1.8)$$

Выборочная дисперсия равна среднему арифметическому квадратов значений выборки минус квадрат выборочного среднего.

Выборочная дисперсия s^2 – это дисперсия выборочной случайной величины X^* , т.е. $s^2 = DX^*$.

Число s называется при этом *выборочным средним квадратичным отклонением (выборочным СКВО)*.

Выборочная асимметрия

Выборочная асимметрия A^* определяется через центральный выборочный момент третьего порядка $\mu_3^* = \sum_{i=1}^k w_i (x_i^* - \bar{x})^3$ соотношением

$$A^* = \frac{\mu_3^*}{s^3}, \quad (1.1.9)$$

где s – выборочное СКВО.

Выборочный эксцесс

Выборочный эксцесс E^* определяется формулой

$$E^* = \frac{\mu_4^*}{s^4} - 3, \quad (1.1.10)$$

где s – выборочное СКВО, а $\mu_4^* = \sum_{i=1}^k w_i (x_i^* - \bar{x})^4$ – центральный *выборочный момент четвертого порядка*.

ЗАМЕЧАНИЕ

Все выборочные характеристики являются функциями наблюдений. Следовательно, они являются статистиками.

Пример 1.1.5

Вычислим выборочное среднее и выборочную дисперсию в примере 1.1.3 (табл. 1.1.1). По формуле (1.1.5)

$$\bar{x} = 2 \cdot 0,16 + 3 \cdot 0,32 + 4 \cdot 0,4 + 5 \cdot 0,12 = 3,48.$$

Выборочную дисперсию вычислим, пользуясь ее свойством (1.1.8)

$$s^2 = 4 \cdot 0,16 + 9 \cdot 0,32 + 16 \cdot 0,4 + 25 \cdot 0,12 - 3,48^2 = \\ = 0,64 + 2,88 + 6,4 + 3 - 12,1104 = 0,8096.$$

Выборочное среднее квадратичное отклонение равно $s = 0,8998$.

1.1.5. Интервальный ряд распределения

Если есть основания предполагать, что генеральная совокупность X имеет непрерывный закон распределения, то строят *интервальный (группированный)* статистический ряд распределения.

Весь диапазон вариационного ряда – отрезок $[x_1^*, x_n^*]$ делят на l интервалов (обычно одинаковой длины h):

$$[\tilde{x}_1^*, \tilde{x}_2^*], [\tilde{x}_2^*, \tilde{x}_3^*], \dots, [\tilde{x}_i^*, \tilde{x}_{i+1}^*], \dots, [\tilde{x}_l^*, \tilde{x}_{l+1}^*],$$

где

$$h = \frac{x_n^* - x_1^*}{l}, \quad \tilde{x}_1^* = x_1^*, \quad \tilde{x}_k^* = x_1^* + (k-1)h, \quad \tilde{x}_{l+1}^* = x_n^*. \quad (1.1.11)$$

В таблицу вносят интервалы $[\tilde{x}_i^*, \tilde{x}_{i+1}^*]$, абсолютные частоты n_i , равные количеству наблюдений, попавших в каждый интервал, и соответствующие относительные частоты $w_i = \frac{n_i}{n}$ (табл. 1.3).

Интервальный ряд распределения

Таблица 1.1.3

Интервалы	$[\tilde{x}_1^*, \tilde{x}_2^*]$	$[\tilde{x}_2^*, \tilde{x}_3^*]$	...	$[\tilde{x}_i^*, \tilde{x}_{i+1}^*]$	...	$[\tilde{x}_l^*, \tilde{x}_{l+1}^*]$	Σ
Абсолютные частоты	n_1	n_2	...	n_i	...	n_l	n
Абсолютные частоты	w_1	w_2	...	w_i	...	w_l	1

ЗАМЕЧАНИЕ 1

Если выборка делается из генеральной совокупности дискретно распределенной случайной величины, но число наблюдений очень велико, то для нее также составляют интервальный ряд распределения.

ЗАМЕЧАНИЕ 2

Если неизвестно, к какому типу принадлежит случайная величина, из генеральной совокупности которой сделана выборка, то статистическую обработку проводят как с непрерывной случайной величиной.

ЗАМЕЧАНИЕ 3

Если есть основания полагать, что случайная величина X принимает значения на всей числовой оси $(-\infty; +\infty)$, то в интервальный ряд распределения добавляют промежутки $(-\infty; \tilde{x}_1^*)$ и $(\tilde{x}_{l+1}^*; +\infty)$, в которые попадает относительно мало выборочных значений. В этом случае можно использовать формулы (1.1.11), полагая в них $\tilde{x}_1^* = -\infty$ и $\tilde{x}_{l+1}^* = +\infty$.

ЗАМЕЧАНИЕ 4

Если весь диапазон выборки разбит на интервалы и какое-то выборочное значение совпадает с границей двух интервалов, то к абсолютным частотам обоих интервалов добавляют 0,5.

ЗАМЕЧАНИЕ 5

Число интервалов l , на которые разбивают диапазон выборки, определяют по одному из следующих правил:

- $l = 1 + 3,22 \ln n$, $5 \leq l \leq 25$ – формула Стэрджеса;
- $l = \lfloor \sqrt{n} \rfloor$, $5 \leq l \leq 25$;
- $l \leq 5 \lg n$, $6 \leq l \leq 20$.

Статистическим приближением функции распределения $F(x)$ генеральной совокупности X в случае интервального статистического ряда является *кумулята*, которую обозначают так же как и эмпирическую функцию распределения $F_n^*(x)$.

Если генеральная совокупность X имеет дискретный закон распределения, то выборочной случайной величиной X^* является случайная величина, которая принимает значения, равные серединам интервалов $a_i = \frac{\tilde{x}_i^* + \tilde{x}_{i+1}^*}{2}$, с вероятностями w_i , где $(i = 1, 2, \dots, l)$.

Кумулятой в данном случае является кусочно–постоянная функция со скачками в точках $a_i = \frac{\tilde{x}_i^* + \tilde{x}_{i+1}^*}{2}$ ($i = 1, 2, \dots, l$). Величины этих скачков равны относительным частотам w_i ($i = 1, 2, \dots, l$) (рис. 1.1.3).




Рис. 1.1.3

Если генеральная совокупность X имеет непрерывный закон распределения, то кумулята должна быть непрерывной функцией. В данном случае кумулята является кусочно–линейной функцией, график которой проходит через точки $\left(\tilde{x}_i^*; \sum_{j=1}^i w_j\right)$, ($i = 1, 2, \dots, l$) (рис. 1.1.4).




Рис. 1.1.4.

Для непрерывно распределенной генеральной совокупности X функция $y = f_n^*(x)$, для которой справедливо соотношение

$$f_n^*(x) = \left(F_n^*(x)\right)',$$

является статистическим аналогом плотности распределения. График этой функции называется *гистограммой*.

Чтобы выяснить, как должна строиться гистограмма, получим уравнение отрезка кумуляты $y = F_n^*(x)$ на промежутке $[\tilde{x}_i^*; \tilde{x}_{i+1}^*]$. Для этого используем уравнение прямой, проходящей через две точки $(x_1; y_1)$ и $(x_2; y_2)$ $\frac{x - x_1}{x_2 - x_1} = \frac{y - y_1}{y_2 - y_1}$.

Поскольку кумулята проходит через точки $\left(\tilde{x}_i^*; \sum_{j=1}^i w_j\right)$ и $\left(\tilde{x}_{i+1}^*; \sum_{j=1}^{i+1} w_j\right)$, то ее уравнение на отрезке $\left[\tilde{x}_i^*; \tilde{x}_{i+1}^*\right]$ длины $h = \tilde{x}_{i+1}^* - \tilde{x}_i^*$ будет иметь вид:

$$\frac{x - \tilde{x}_i^*}{h} = \frac{y - \sum_{j=1}^i w_j}{w_i},$$

которое, решив относительно переменной y , можно записать в виде

$$y = \frac{w_i}{h}(x - \tilde{x}_i^*) + \sum_{j=1}^i w_j, \quad \forall x \in [\tilde{x}_i^*; \tilde{x}_{i+1}^*], \quad (i = 1, 2, \dots, l).$$

Плотность распределения на отрезке $[\tilde{x}_i^*; \tilde{x}_{i+1}^*]$ определим из условия

$$y' = (F_n^*(x))' = \frac{w_i}{h} = \text{const}, \quad \text{при } x \in [\tilde{x}_i^*; \tilde{x}_{i+1}^*], \quad (i = 1, 2, \dots, l).$$

Следовательно, гистограмма является ступенчатой фигурой (рис. 1.1.5), состоящая из прямоугольников, основаниями которых служат отрезки длиной h , а высоты равны $\frac{w_i}{h}$.




Рис. 1.1.5.

ЗАМЕЧАНИЕ 1

Величины $\frac{w_i}{h}$ называются *плотностями частоты*.

ЗАМЕЧАНИЕ 2

Гистограмма обладает всеми свойствами плотности распределения:

1. Чем вероятнее какое-нибудь значение случайной величины X , тем больше этих значений в выборке и, следовательно, тем больше плотность частоты $\frac{w_i}{h}$ и тем выше на соответствующем отрезке гистограмма.
2. Поскольку площадь под гистограммой равна суммарной площади всех прямоугольников, то для нее справедливо соотношение

$$S = \sum_{i=1}^l \frac{w_i}{h} \cdot h = \sum_{i=1}^l w_i = 1.$$

Иногда наряду с гистограммой строят полигон, соединяя точки гистограммы с абсциссами $a_i = \frac{\tilde{x}_i^* + \tilde{x}_{i+1}^*}{2}$ ($i = 1, 2, \dots, l$), равными серединам интервалов статистического ряда (рис. 1.1.6). Для «завершенности» кривой середины первого и последнего интервалов можно соединить с точками с абсциссами $a_1 - \frac{h}{2}$ и $a_l + \frac{h}{2}$, лежащими на оси абсцисс.




Рис. 1.1.6.

Эта кривая более «похожа» на график плотности распределения, чем гистограмма. Однако площадь под этой кривой уже не будет равна 1.

По виду гистограммы и полигона можно делать предположение о законе распределения генеральной совокупности, если он не известен. Например, по гистограмме на рис. 1.1.7 можно предположить, что генеральная совокупность X распределена по нормальному закону.




Рис. 1.1.7.

Если гистограмма и соответствующий полигон имеют вид, показанный на рис. 1.1.8, то, очевидно, закон распределения X больше «похож» на показательный. Поиск плотности распределения $f(x)$, наилучшим образом соответствующей построенным кривым, называется *выравниванием статистических наблюдений*.




Рис. 1.1.8.

Иногда закон распределения генеральной совокупности заранее известен, но не известны параметры этого распределения. В этом случае параметры распределения можно выбрать так, чтобы первые два момента (математическое ожидание и дисперсия) совпадали с соответствующими выборочными моментами. Например, ошибки измерения, как правило, подчиняются нормальному закону. Тогда неизвестные параметры a и σ нормального закона можно приближенно положить равными

$$a \approx \bar{x}, \sigma \approx s \text{ или } \sigma \approx \bar{s},$$

и считать плотность распределения равной

$$f(x) = \frac{1}{\sqrt{2\pi} s} e^{-\frac{(x-\bar{x})^2}{2s^2}}.$$

Если построен интервальный статистический ряд, то все выборочные значения $x_i \in [\tilde{x}_i^*; \tilde{x}_{i+1}^*]$ считают равными $a_i = \frac{\tilde{x}_i^* + \tilde{x}_{i+1}^*}{2}$ ($i=1, 2, \dots, l$). В этом случае выборочное среднее и выборочная дисперсия вычисляются по формулам:

$$\bar{x} = \frac{1}{n} \sum_{k=1}^l a_k n_k = \sum_{k=1}^l a_k w_k,$$

$$s^2 = \frac{1}{n} \sum_{k=1}^l (a_k - \bar{x})^2 n_k = \frac{1}{n} \sum_{k=1}^l a_k^2 n_k - \bar{x}^2 = \sum_{k=1}^l a_k^2 w_k - \bar{x}^2.$$

1.1.6. Точечные статистические оценки

Точечной называется оценка, которая определяется одним числом. Например, выборочное среднее $\bar{x}$ и выборочная дисперсия s^2 являются точечными статистическими оценками.

Одной из центральных задач математической статистики является задача оценки теоретического распределения случайной величины на основе выборочных данных. При этом предполагается, что закон распределения генеральной совокупности известен, но неизвестны его параметры, такие, например, как математическое ожидание и дисперсия. Требуется найти приближенные значения этих параметров, т.е. получить их *статистические оценки*.

Пусть θ^* – статистическая оценка некоторого параметра θ теоретического распределения. Если взять несколько (k) выборок одного и того же объема, то в общем случае получим столько же разных оценок $\theta_1^*, \dots, \theta_k^*$, которые, вообще говоря, различны между собой. Таким образом, оценку θ^* можно рассматривать как случайную величину, а числа $\theta_1^*, \dots, \theta_k^*$ – как ее возможные значения.

Определение 1.1.11

Несмещенной оценкой параметра θ называется такая статистическая оценка θ^* , математическое ожидание которой равно оцениваемому параметру, т.е. $M[\theta^*] = \theta$. В противном случае оценка θ^* называется *смещенной*.

Определение 1.1.12

Эффективной оценкой параметра θ называется статистическая оценка θ^* , которая при одних и тех же объемах выборки имеет наименьшую дисперсию.

ЗАМЕЧАНИЕ

Если $D[\theta^*] \xrightarrow{n \rightarrow \infty} 0$, то статистическую оценку θ^* называют асимптотически эффективной. Если получена какая-то одна оценка θ^* и не сравниваются между собой несколько статистических оценок, то стараются получить асимптотически эффективную оценку.

Определение 1.1.13

Состоятельной оценкой параметра θ называется статистическая оценка θ^* , которая при увеличении объема выборки стремится по вероятности к оцениваемому параметру, т.е. $P(\theta^* = \theta / n \rightarrow \infty) = 1$.

1.1.7. Выборочное среднее

Теорема 1.1.1

Если выборка $x_1, x_2, \dots, x_n$ извлечена из генеральной совокупности X , то выборочное среднее $\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$ является несмещенной, состоятельной и эффективной оценкой математического ожидания генеральной совокупности $M[X] = a$.

Доказательство

1. Покажем, что $\bar{x}$ – несмещенная оценка. Для этого будем рассматривать $\bar{x}$ как случайную величину $\bar{X}$, а выборочные значения $x_1, x_2, \dots, x_n$ как значения независимых, распределенных по закону распределения генеральной совокупности случайных величин $X_1, X_2, \dots, X_n$. Это значит, что они имеют одинаковые с генеральной совокупностью математическое ожидание $M[X] = a$ и дисперсию $D[X] = \sigma^2$.

Математическое ожидание выборочного среднего $\bar{X}$, как случайной величины равно

$$M[\bar{X}] = \frac{M[X_1 + X_2 + \dots + X_n]}{n} = \frac{n \cdot a}{n} = a.$$

Следовательно, выборочное среднее является несмещенной оценкой математического ожидания.

2. Состоятельность оценки следует из закона больших чисел, по которому среднее арифметическое одинаково распределенных с генеральной совокупностью X случайных величин $X_1, X_2, \dots, X_n$:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} \xrightarrow[n \rightarrow \infty]{p.} M[X] = a.$$

3. Вычислим дисперсию выборочного среднего $\bar{X}$, как случайной величины:

$$D[\bar{X}] = D\left[\frac{X_1 + X_2 + \dots + X_n}{n}\right] = \frac{1}{n^2} \sum_{i=1}^n D[X_i] = \frac{n \cdot \sigma^2}{n^2} = \frac{\sigma^2}{n} \xrightarrow[n \rightarrow \infty]{} 0.$$

Следовательно, выборочное среднее является *асимптотически эффективной* оценкой математического ожидания.

ЗАМЕЧАНИЕ

Поскольку выборочное среднее $\bar{x} = \sum_{i=1}^n \frac{x_i}{n}$ является суммой независимых одинаково распределенных

случайных величин $\frac{X_1}{n}, \frac{X_2}{n}, \dots, \frac{X_n}{n}$, то при существовании у генеральной совокупности X конечной

дисперсии для последовательности $\left\{\frac{X_i}{n}\right\}_{i=1}^{\infty}$ справедлива центральная предельная теорема (т.Леви).

Следовательно, в этом случае выборочное среднее $\bar{x}$ асимптотически нормально, т.е. при больших объемах выборки n подчиняется нормальному закону с параметрами a и $\frac{\sigma}{\sqrt{n}}$, где a и σ – математическое ожидание и СКВО генеральной совокупности X .

1.1.8. Выборочная дисперсия

Теорема 1.1.2

Выборочная дисперсия $s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ является смещенной оценкой дисперсии генеральной совокупности $D[X] = \sigma^2$.

Доказательство

Рассмотрим выборочную дисперсию $s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ и найдем математическое ожидание выборочной дисперсии s^2 , как случайной величины:

$$\begin{aligned} M[s^2] &= M\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (\sigma^2 + a^2) - \left(\frac{\sigma^2}{n} + a^2\right) = \\ &= \frac{n \cdot (\sigma^2 + a^2)}{n} - \frac{\sigma^2}{n} - a^2 = \sigma^2 - \frac{\sigma^2}{n} = \frac{n-1}{n} \sigma^2. \end{aligned}$$

Таким образом, математическое ожидание выборочной дисперсии не равно оцениваемой дисперсии генеральной совокупности σ^2 и, следовательно, оценка является смещенной.

ЗАМЕЧАНИЕ 1

Чтобы «исправить» выборочную дисперсию, ее нужно умножить на дробь $\frac{n}{n-1}$. В результате получим «исправленную» выборочную дисперсию

$$\bar{s}^2 = \frac{n}{n-1} s^2,$$

или, если составлен статистический ряд, то:

$$\bar{s}^2 = \frac{1}{n-1} \sum_{i=1}^k n_i (x_i^* - \bar{x})^2, \quad \bar{s}^2 = \frac{n}{n-1} \sum_{i=1}^k w_i (x_i^* - \bar{x})^2$$

ЗАМЕЧАНИЕ 2

Сравнивая выборочную дисперсию $s^2 = \frac{1}{n} \sum_{i=1}^k n_i (x_i^* - \bar{x})^2$ и «исправленную» выборочную дисперсию

$\bar{s}^2 = \frac{1}{n-1} \sum_{i=1}^k n_i (x_i^* - \bar{x})^2$, видим, что они отличаются только знаменателем. Очевидно, что при достаточно больших n они различаются мало. Поэтому на практике пользуются «исправленной» выборочной дисперсией, если $n < 30$.

«Исправленным» выборочным *средним квадратичным отклонением* называется арифметический квадратный корень из «исправленной» выборочной дисперсии:

$$\bar{s} = \sqrt{\frac{1}{n-1} \sum_{i=1}^k n_i (x_i^* - \bar{x})^2}.$$

Теорема 1.1.3

Выборочная дисперсия $s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ является состоятельной оценкой дисперсии генеральной совокупности $D[X] = \sigma^2$.

Доказательство

Представим выборочную дисперсию в виде:

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2.$$

Первое слагаемое в последней формуле является средним арифметическим одинаково распределенных независимых случайных величин $X_1^2, X_2^2, \dots, X_n^2$, имеющих конечное математическое ожидание. Следовательно, по закону больших чисел справедливо:

$$\sum_{i=1}^n x_i^2 \xrightarrow[n \rightarrow \infty]{p.} M \left(\sum_{i=1}^n x_i^2 \right).$$

$$\text{Поскольку } M \left(\sum_{i=1}^n x_i^2 \right) = \frac{1}{n} \sum_{i=1}^n M[X_i^2] = \sum_{i=1}^n (D[X_i] + (M[X_i])^2) =$$

$$= \frac{1}{n} \sum_{i=1}^n (D[X_i] + (M[X_i])^2) = \frac{1}{n} \sum_{i=1}^n (\sigma^2 + a^2) = \frac{1}{n} \cdot n \cdot (\sigma^2 + a^2) = \sigma^2 + a^2,$$

$$\text{то } \frac{1}{n} \sum_{i=1}^n x_i^2 \xrightarrow[n \rightarrow \infty]{p.} \sigma^2 + a^2.$$

Второе слагаемой в формуле для выборочной дисперсии, вследствие состоятельности статистической оценки $\bar{x}$ для математического ожидания a , стремится по вероятности к математическому ожиданию $M[X^2] = a^2$, т.е.

$$\bar{x}^2 \xrightarrow[n \rightarrow \infty]{p.} a^2.$$

Тогда

$$s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 \xrightarrow[n \rightarrow \infty]{p.} \sigma^2 + a^2 - a^2 = \sigma^2.$$

Значит, s^2 является состоятельной оценкой генеральной дисперсии $D[X] = \sigma^2$.

ЗАМЕЧАНИЕ

Эффективность оценки s^2 обычно не проверяют. Можно доказать, что эффективной оценкой генеральной дисперсии является не s^2 , а статистика $s_y^2 = \frac{1}{n} \sum_{i=1}^n (x_i - a)^2$, где $a = M[X]$.

1.2. Интервальное оценивание выборочных данных

1.2.1. Доверительный интервал

При выборке малого объема точечная оценка может существенно отличаться от оцениваемого параметра, поэтому используют интервальные оценки.

Интервальной называют оценку, которая определяется двумя числами – концами интервала.

Пусть θ^* – найденная по выборке точечная оценка неизвестного параметра θ . Поскольку θ^* случайная величина, то разность $|\theta - \theta^*|$ также случайная величина. Поэтому неравенство $|\theta - \theta^*| < \delta$ при заданном значении δ может выполняться с некоторой вероятностью.

Обычно задается вероятность, с которой оцениваемый параметр распределения попадает в интервал (θ_1^*, θ_2^*) .

Определение 1.2.1

Интервал (θ_1^*, θ_2^*) , такой, что $P\{\theta_1^* < \theta < \theta_2^*\} = \beta$, где β – заданная вероятность, называется *доверительным интервалом*, а вероятность β – *доверительной вероятностью (надежностью)*.

Доверительная вероятность задается, и по ней определяют доверительный интервал. Обычно надежность выбирают в пределах: $0,9 \leq \beta \leq 0,998$.

ЗАМЕЧАНИЕ 1

Следует обратить внимание, что параметр θ не случайная величина. Это конкретное число, которое неизвестно.

Случайными величинами являются границы доверительного интервала. Поэтому говорят, что доверительный интервал (θ_1^*, θ_2^*) покрывает значение θ с вероятностью β .

ЗАМЕЧАНИЕ 2

Доверительный интервал может быть симметричным, т.е. иметь вид $(\theta^* - \delta, \theta^* + \delta)$.

1.2.2. Доверительный интервал для оценки математического ожидания нормального распределения при известном среднем квадратичном отклонении

Пусть известно, что генеральная совокупность X имеет нормальное (гауссовское) распределение с параметрами a и σ . Известно ее среднее квадратичное отклонение σ . Математическое ожидание a не известно, но получена его статистическая оценка – выборочное среднее $\bar{x}$.

Требуется найти доверительный интервал для математического ожидания a с заданной надежностью β .

Так как выборочное среднее является случайной величиной, то ее обозначим $\bar{X}$. Известно (см. теорема 1.1.1) математическое ожидание выборочного среднего $M[\bar{X}] = a$, а его дисперсия и среднее квадратичное отклонение соответственно равны $\frac{\sigma^2}{n}$, $\frac{\sigma}{\sqrt{n}}$.

Поскольку плотность нормального распределения симметрична относительно математического ожидания и среднее выборочное является несмещенной оценкой математического ожидания, то доверительный интервал выбирается симметричным.

Вероятность попадания выборочного среднего в некоторую t_β - окрестность математического ожидания a задана и равна β :

$$P\{|\bar{x} - a| < t_\beta\} = P\{\bar{x} - t_\beta < a < \bar{x} + t_\beta\} = \beta.$$

Интервал $(\bar{x} - t_\beta; \bar{x} + t_\beta)$ покрывает с доверительной вероятностью β математическое ожидание a .

Параметр t_β , который определяет симметричный доверительный интеграл, называется *квантилем*. Чтобы найти его, используем функцию Лапласа $\Phi(x)$ – функцию распределения нормальной случайной величины. Учитывая, что выборочное среднее $\bar{X}$ также имеет нормальное распределение (теорема Бернулли), можно выразить заданную доверительную вероятность через функцию Лапласа по формуле

$$P\{|\bar{x} - a| < t_\beta\} = P\{a - t_\beta < \bar{x} < a + t_\beta\} = \Phi\left(\frac{t_\beta}{\frac{\sigma}{\sqrt{n}}}\right) - \Phi\left(-\frac{t_\beta}{\frac{\sigma}{\sqrt{n}}}\right) = 2\Phi\left(\frac{t_\beta \sqrt{n}}{\sigma}\right).$$

Тогда $2\Phi\left(\frac{t_\beta \sqrt{n}}{\sigma}\right) = \beta$, или $\Phi\left(\frac{t_\beta \sqrt{n}}{\sigma}\right) = \frac{\beta}{2}$.

Из этого условия определяется квантиль t_β .

$$\frac{t_{\beta}\sqrt{n}}{\sigma} = \Phi^{-1}\left(\frac{\beta}{2}\right), \quad t_{\beta} = \frac{\sigma}{\sqrt{n}}\Phi^{-1}\left(\frac{\beta}{2}\right).$$

где $\Phi^{-1}(x)$ – обратная к $\Phi(x)$ функция.

Доверительный интервал, который покрывает с надежностью β математическое ожидание a будет иметь вид

$$\left(\bar{x} - \frac{\sigma}{\sqrt{n}}\Phi^{-1}\left(\frac{\beta}{2}\right); \bar{x} + \frac{\sigma}{\sqrt{n}}\Phi^{-1}\left(\frac{\beta}{2}\right)\right).$$

ЗАМЕЧАНИЕ

При разных значениях $\bar{x}$ границы интервала меняются.

Пример 1.2.1

Случайная величина X имеет нормальное распределение с известным средним квадратичным отклонением $\sigma = 3$. Найти доверительный интервал для оценки неизвестного математического ожидания по выборочному среднему $\bar{x}$, если объем выборки $n = 36$, а надежность оценки $\beta = 0,95$.

Решение

$\Phi(x) = \frac{\beta}{2} = 0,475$. Найдем по таблице 5.2 для функции Лапласа $\Phi^{-1}\left(\frac{\beta}{2}\right) = 1,96$. Определим t_{β} :

$$t_{\beta} = \frac{\sigma}{\sqrt{n}}\Phi^{-1}\left(\frac{\beta}{2}\right) = \frac{1,96 \cdot 3}{\sqrt{36}} = 0,98.$$

Доверительный интервал имеет вид $(\bar{x} - 0,98; \bar{x} + 0,98)$.

Если требуется определить минимальный объем выборки n , для которого справедливо неравенство $P\{|\bar{x} - a| < \delta\} = \beta$, где число δ и надежность β – заданы, то, используя формулу

$\delta = t_{\beta} = \frac{\sigma}{\sqrt{n}}\Phi^{-1}\left(\frac{\beta}{2}\right)$, определяют

$$\sqrt{n} = \frac{\sigma}{\delta}\Phi^{-1}\left(\frac{\beta}{2}\right).$$

Следовательно, минимальное значение объема выборки определяется из неравенства

$$n \geq \frac{\sigma^2}{\delta^2} \left(\Phi^{-1}\left(\frac{\beta}{2}\right) \right)^2.$$

Пример 1.2.2

Случайная величина X имеет нормальное распределение с известным средним квадратичным отклонением $\sigma = 3$. Найти минимальный объем выборки, чтобы с надежностью $\beta = 0,95$ выборочное среднее $\bar{x}$ отклонялось от математического ожидания не больше, чем на $\delta = 0,98$.

Решение

$\sqrt{n} = \frac{\sigma}{\delta}\Phi^{-1}\left(\frac{\beta}{2}\right)$. Поскольку $\Phi^{-1}\left(\frac{\beta}{2}\right) = 1,96$, то $\sqrt{n} = \frac{3}{0,98} \cdot 1,96 = 6$. Следовательно,

наименьший объем выборки 36.

1.2.3. Число степеней свободы

Введем понятие *числа степеней свободы*. Говорят, что любая комбинация k независимых случайных величин $X_1, X_2, \dots, X_k$, в частности их сумма, имеет k *степеней свободы*, так как каждая составляющая может менять свое значение независимо от других значений.

Например, последовательность измерений $X_1, X_2, \dots, X_k$ или их сумма имеет k степеней свободы. Точно также и сумма квадратов этих величин имеет k степеней свободы.

Если же для системы случайных величин $X_1, X_2, \dots, X_k$ заданы некоторые дополнительные условия, связывающие их, то число степеней свободы уменьшается.

Например, если найти среднее значение полученных в результате выборки значений $x_1, x_2, \dots, x_k$, т.е. $\bar{\tilde{o}} = \frac{\tilde{o}_1 + \tilde{o}_2 + \dots + \tilde{o}_k}{k}$, и зафиксировать это значение для соответствующих k случайных величин $X_1, X_2, \dots, X_k$ т.е. признать верным выражение $\bar{X} = \frac{\tilde{O}_1 + \tilde{O}_2 + \dots + \tilde{O}_k}{k}$

для всех значений этих величин, то одну из величин можно выразить через остальные. Это означает, что система случайных величин $X_1, X_2, \dots, X_k$ оказалась связанной и она потеряла одну степень свободы.

1.2.4. Основные законы распределения статистических оценок

Нормальное распределение было рассмотрено ранее. Рассмотрим другие виды распределения.

Распределение «хи-квадрат»

Пусть $X_1, X_2, \dots, X_n$ – независимые нормально распределенные случайные величины, для которых:

- 1) математическое ожидание каждой из них равно нулю, т.е.

$$M[X_i] = 0, \quad i = 1, \dots, n;$$

- 2) среднее квадратичное отклонение равно единице, т.е.

$$CKBO = 1.$$

Тогда закон распределения случайной величины

$$\chi_n^2 = X_1^2 + X_2^2 + \dots + X_n^2$$

называется *законом хи-квадрат с n степенями свободы*.

Число степеней свободы совпадает с числом слагаемых $\tilde{O}_1^2, \tilde{O}_2^2, \dots, \tilde{O}_n^2$ в формуле для χ_n^2 . Если на случайные величины $X_1, X_2, \dots, X_n$ наложены дополнительные связи, то число степеней свободы уменьшается на количество связывающих $X_1, X_2, \dots, X_n$ зависимостей.

Плотность распределения случайной величины χ_n^2 имеет вид

$$f_{\chi_n^2}(x) = \begin{cases} 0, & x \leq 0, \\ \frac{e^{-\frac{x}{2}} \cdot x^{\frac{n}{2}-1}}{2^{\frac{n}{2}} \cdot \Gamma(\frac{n}{2})}, & x > 0, \end{cases}$$

где $\Gamma(x) = \int_0^\infty t^{x-1} \cdot e^{-t} dt$ – *гамма-функция*, для которой выполняется равенство $\Gamma(n+1) = n!$.

Распределение χ_n^2 затабулировано. По заданному числу степеней свободы n и заданной доверительной вероятности β :

$$P\{\chi_n^2 > \chi_{n,\beta}^2\} = \beta$$

из таблицы 5.2.3 определяются значения $\chi_{n,\beta}^2$.

График плотности распределения случайной величины χ_n^2 при $n = 1, 2, 3$ показан на рис. 1.2.1.




Рис. 1.2.1.

Случайная величина χ_n^2 является асимптотически нормальной, так как представляет собой сумму независимых одинаково распределенных случайных величин с конечной дисперсией (по центральной предельной теореме). Это означает, что при $n \rightarrow \infty$ (достаточно $n \geq 30$) плотность распределения χ_n^2 равно плотности распределения нормальной случайной величины. При этом параметрами нормального распределения будут математическое ожидание и среднее квадратическое отклонение случайной величины χ_n^2 .

Параметрами нормального закона для случайной величины χ_n^2 будут $(n, \sqrt{2n})$ и ее плотность при достаточно больших n ($n \geq 30$) можно считать приближенно равной:

$$f_{\chi_n^2}(x) \approx \frac{1}{\sqrt{2\pi n}} e^{-\frac{(x-n)^2}{4n}}.$$

Распределение Стьюдента

Пусть X нормально распределенная случайная величина и $\tilde{O}_1, \tilde{O}_2, \dots, \tilde{O}_i$ – независимые случайные величины, имеющие такое же распределение, как и X . При этом параметрами нормального распределения являются:

- 1) математическое ожидание

$$M[X_i] = 0, \quad i = 0, 1, \dots, n;$$

- 2) среднее квадратичное отклонение

$$CKBO = 1.$$

Тогда случайная величина

$$T_n = \frac{X}{\chi_n^2} = \frac{X}{\sqrt{\sum_{i=1}^n X_i^2}}$$

имеет распределение, которое называют *распределением Стьюдента (Т-распределением)* с n степенями свободы.

Плотность вероятности случайной величины T_n имеет вид:

$$f(x) = b_n \left(1 + \frac{x^2}{n} \right)^{-\frac{n+1}{2}},$$

где $b_n = \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2}) \cdot \sqrt{\pi n}}.$

Плотность распределения Стьюдента является четной функцией. График ее показан на рис. 1.2.2. Если задать доверительную вероятность β , такую что

$$P\{|T_n| < t_{n,\beta}\} = \beta,$$

то значения $t_{n,\beta}$ можно найти из таблицы распределения Стьюдента (табл. 5.4) по заданным числу степеней свободы n и вероятности β .




Рис. 1.2.2.

Поскольку плотность распределения Стьюдента является четной функцией (рис. 1.2.2), то последнее соотношение можно переписать в виде:

$$2P\{0 < T_n < t_{n,\beta}\} = \beta, \text{ или } P\{0 < T_n < t_{n,\beta}\} = \frac{\beta}{2}.$$

При $n \rightarrow \infty$ распределение Стьюдента приближается к нормальному распределению с параметрами $M[T_n]$ и $\sqrt{D[T_n]}$.

Ясно, что математическое ожидание распределения Стьюдента

$$M[T_n] = b_n \int_{-\infty}^{+\infty} x \cdot \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}} dx = 0$$

как интеграл от нечетной функции по симметричному промежутку.

Дисперсию распределения Стьюдента при $n \geq 3$ равна:

$$D[T_n] = \frac{n}{n-2}.$$

При $n=1$ дисперсия $D[T_1] = b_1 \int_{-\infty}^{+\infty} x^2 (1+x^2)^{-1} dx = b_1 \int_{-\infty}^{+\infty} \frac{x^2}{1+x^2} dx$ не определена, поскольку

$\frac{x^2}{1+x^2} \rightarrow 1$ и несобственный интеграл расходится.

При $n=2$ дисперсия также не определена, так как

$D[T_2] = b_2 \int_{-\infty}^{+\infty} x^2 \left(1 + \frac{x^2}{2}\right)^{-\frac{3}{2}} dx = b_2 \int_{-\infty}^{+\infty} \frac{x^2}{\left(1 + \frac{x^2}{2}\right)^{\frac{3}{2}}} dx$, а несобственный интеграл $\int_{-\infty}^{+\infty} \frac{x^2}{\left(1 + \frac{x^2}{2}\right)^{\frac{3}{2}}} dx$ является

расходящимся, поскольку $\frac{x^2}{\left(1 + \frac{x^2}{2}\right)^{\frac{3}{2}}} \underset{x \rightarrow \pm\infty}{\sim} \frac{x^2}{\left(\frac{x^2}{2}\right)^{\frac{3}{2}}} = \frac{2\sqrt{2}}{x}$.

Случайная величина T_n является асимптотически нормальной с параметрами $\left(0, \frac{\sqrt{n-2}}{\sqrt{n}}\right)$. При достаточно больших n ($n \geq 20$) можно считать плотностью распределения Стьюдента функцию

$$f_{T_n}(x) \approx \frac{\sqrt{n-2}}{\sqrt{2\pi n}} e^{-\frac{x^2(n-2)}{2n}}.$$

1.2.5. Доверительный интервал для математического ожидания нормального распределения при неизвестном среднем квадратичном отклонении

Пусть генеральная совокупность X имеет нормальное распределение с параметрами a и σ . Пусть $x_1, x_2, \dots, x_n$ - простая выборка из этой генеральной совокупности. Пусть значение σ не известно.

Тогда вместо центрированной случайной величины $\frac{\bar{x} - a}{\sigma}$ рассматривается случайная величина $\frac{\bar{x} - a}{\bar{s}} = \frac{\bar{x} - a}{\bar{s}} \sqrt{n}$, где $\bar{x}$ - выборочное среднее, $\bar{s}$ - исправленное выборочное среднее квадратичное отклонение. Обозначим ее $T_n = \frac{\bar{x} - a}{\bar{s}} \sqrt{n}$.

Если рассматривать смещенную выборочную дисперсию s , то

$$T_n = \frac{\bar{x} - a}{s \cdot \frac{\sqrt{n}}{\sqrt{n-1}}} \sqrt{n} = \frac{\bar{x} - a}{s} \sqrt{n-1}.$$

$T_{n-1} = \frac{\bar{x} - a}{s} \sqrt{n-1}$ является функцией наблюдений. Следовательно, T_{n-1} является статистикой. Доказано (мы этого делать не будем), что статистика T_{n-1} имеет распределение Стьюдента с $n-1$ степенью свободы.

Если задать доверительную вероятность β , такую, чтобы выполнялось соотношение

$$P\{|T_{n-1}| < t_{\beta, n-1}\} = \beta,$$

то значения $t_{\beta, n-1}$ при заданном числе степеней свободы $n-1$ и заданной доверительной вероятности β можно найти из таблицы распределения Стьюдента. Тогда можно построить доверительный интервал для математического ожидания при неизвестном среднем квадратичном отклонении σ .

$$P\left\{\left|\frac{\bar{x} - a}{s}\right| \sqrt{n-1} < t_{\beta, n-1}\right\} = \beta, \quad P\left\{|\bar{x} - a| < \frac{s}{\sqrt{n-1}} t_{\beta, n-1}\right\} = \beta,$$

$$P\left\{-\frac{s}{\sqrt{n-1}} t_{\beta, n-1} < \bar{x} - a < \frac{s}{\sqrt{n-1}} t_{\beta, n-1}\right\} = \beta, \quad P\left\{\bar{x} - \frac{s}{\sqrt{n-1}} t_{\beta, n-1} < a < \bar{x} + \frac{s}{\sqrt{n-1}} t_{\beta, n-1}\right\} = \beta.$$

Доверительным интервалом, с надежностью β покрывающим математическое ожидание a гауссовской генеральной совокупности с неизвестным средним квадратичным отклонением σ является интервал

$$\left(\bar{x} - \frac{s}{\sqrt{n-1}} t_{\beta, n-1}, \bar{x} + \frac{s}{\sqrt{n-1}} t_{\beta, n-1}\right).$$

ЗАМЕЧАНИЕ

Если нужно найти минимальный объем выборки n , чтобы с вероятностью β выполнялось неравенство $|\bar{x} - a| < \delta$, где δ - заданное число, то из формулы $\delta = \frac{s}{\sqrt{n-1}} t_{\beta, n-1}$ можно определить

$$\text{минимальный объем выборки } n \geq \left(1 + \frac{s}{\delta} t_{\beta, n-1}\right)^2.$$

1.2.6. Доверительный интервал для оценки среднего квадратичного отклонения нормального распределения

Пусть X – нормально распределенная генеральная совокупность с неизвестными параметрами a и σ . Пусть $x_1, x_2, \dots, x_n$ – простая выборка из генеральной совокупности. Вычислено ее «исправленное» выборочное среднее квадратичное отклонение $\bar{s}$. Требуется найти доверительный интервал, в который попадает среднее квадратичное отклонение σ с заданной надежностью β .

Доказано, что случайная величина $\frac{\bar{s}^2 n}{\sigma^2} = \chi_{n-1}^2$ распределена по закону χ^2 с $n-1$ степенью свободы, поэтому квадратный корень из нее обозначают через χ .

Распределение χ^2 – одностороннее, так как случайная величина χ_n^2 принимает только неотрицательные значения. Поэтому искомый доверительный интервал для среднего квадратического отклонения σ не будет симметричным относительно центра распределения.

Зададим доверительную вероятность β и потребуем, чтобы выполнялось соотношение:

$$P\{t_1 < \chi_{n-1}^2 < t_2\} = \beta.$$

Тогда

$$1 - \beta = 1 - P\{t_1 < \chi_{n-1}^2 < t_2\} = P\{\chi_{n-1}^2 \leq t_1\} + P\{\chi_{n-1}^2 \geq t_2\}.$$




Рис. 1.2.3.

Числа t_1 и t_2 подбираются так, чтобы выполнялось неравенство

$$P\{\chi_{n-1}^2 \leq t_1\} = P\{\chi_{n-1}^2 \geq t_2\} = \frac{1-\beta}{2} \quad (\text{рис. 1.2.3}).$$

Эти числа найдем из таблицы распределения χ^2 (табл. 5.3) по заданной доверительной вероятности β и числу степеней свободы $n-1$, используя соотношения:

$$P\{\chi_{n-1}^2 \geq t_2\} = \frac{1-\beta}{2},$$

$$P\{\chi_{n-1}^2 \leq t_1\} = 1 - P\{\chi_{n-1}^2 > t_1\} = 1 - \frac{1-\beta}{2} = \frac{1+\beta}{2}.$$

Определив t_1 и t_2 , перепишем неравенство

$$P\{t_1 < \chi_{n-1}^2 < t_2\} = \beta,$$

используя соотношение $\frac{\bar{s}^2 n}{\sigma^2} = \chi_{n-1}^2$.

$$\begin{aligned} \beta &= P\left\{t_1 < \frac{n\bar{s}^2}{\sigma^2} < t_2\right\} = P\left\{\frac{1}{t_2} < \frac{\sigma^2}{n\bar{s}^2} < \frac{1}{t_1}\right\} = \\ &= P\left\{\frac{1}{t_2} n\bar{s}^2 < \sigma^2 < n\bar{s}^2 \frac{1}{t_1}\right\} = P\left\{\sqrt{\frac{n}{t_2}} \bar{s} < \sigma < \sqrt{\frac{n}{t_1}} \bar{s}\right\}. \end{aligned}$$

Следовательно, доверительный интервал, который покрывает с вероятностью β параметр σ гауссовской генеральной совокупности имеет вид:

$$\sigma \in \left(\sqrt{\frac{n}{t_2}} \bar{s}; \sqrt{\frac{n}{t_1}} \bar{s} \right).$$

2. Проверка статистических гипотез

В некоторых случаях требуется знать закон распределения генеральной совокупности. Этот закон неизвестен, но можно предположить его определенный вид (например, нормальный). В этом случае говорят, что выдвигается гипотеза: генеральная совокупность распределена нормально.

В других случаях закон распределения известен, но неизвестны его параметры. Тогда можно выдвинуть гипотезу о значении этого параметра.

2.1. Статистические гипотезы

2.1.1. Основная и альтернативная гипотезы. Ошибки первого и второго рода

Определение 2.1.1

Статистической называют гипотезу о виде неизвестного распределения или о параметрах известного распределения на основе выборочных данных.

Определение 2.1.2

Нулевой (основной) называют выдвинутую гипотезу H_0 . *Конкурирующей (альтернативной)* называют гипотезу H_1 , которая противоречит основной.

Например, если гипотеза H_0 : математическое ожидание нормально распределенной случайной величины равно $M_x = 5$, то гипотеза H_1 : $M_x \neq 5$.

В случае, когда основная гипотеза H_0 отвергается, принимается альтернативная гипотеза H_1 .

Статистическими методами проверяется правильность или неправильность выдвинутой гипотезы. При этом может быть принято верное или нет решение. Поэтому различают ошибки двух родов.

Определение 2.1.3

Ошибка первого рода состоит в том, что отвергается правильная гипотеза.

Определение 2.1.4

Ошибка второго рода состоит в том, что принимается неправильная гипотеза.

Определение 2.1.5

Критерием согласия называется правило по которому принимается или отвергается основная гипотеза H_0 .

Поскольку выводы об истинности или ложности гипотезы H_0 делаются на основе выборочных данных, то вывод об истинности или ложности гипотезы H_0 можно делать только с некоторой вероятностью.

Пусть событие A состоит в том, что принимается гипотеза H_0 . Тогда событие $\bar{A}$ - гипотеза H_0 отвергается. Возможные случаи и ошибки, которые могут быть при проверке истинности основной гипотезы хорошо понятны из таблицы 6.

Таблица 2.1.1

Гипотеза Событие	H_0	$\bar{H}_0$
	$P\left(\frac{A}{H_0}\right)$	$P\left(\frac{A}{\bar{H}_0}\right)$
A		

$\bar{A}$	$P\left(\bar{A}/H_0\right)$	$P\left(\bar{A}/\bar{H}_0\right)$
-----------	-----------------------------	-----------------------------------

Ясно, что $P\left(\bar{A}/H_0\right)$ – вероятность ошибки 1 рода, а $P\left(A/\bar{H}_0\right)$ – вероятность сделать ошибку 2 рода.

Определение 2.1.6

Вероятность сделать ошибку 1 рода называется *уровнем значимости* и обозначается через α , т.е.

$$\alpha = P\left(\bar{A}/H_0\right).$$

Определение 2.1.7

Вероятность сделать ошибку 2 рода обозначается через β , т.е.

$$\beta = P\left(A/\bar{H}_0\right),$$

а число $1 - \beta$ называется *мощностью критерия*.

ЗАМЕЧАНИЕ

Обычно уровень значимости задают достаточно малым, чаще всего $\alpha = 0,05$ или $\alpha = 0,01$. Из возможных критериев выбирается самый мощный, т.е. критерий с минимальной вероятностью ошибки 2 рода.

2.1.2. Критерии согласия. Общая схема проверки статистических гипотез

Для проверки выдвинутой основной гипотезы H_0 выбирается критерий согласия. Суть проверки истинности гипотезы H_0 по критерию согласия состоит в том, что выбирается некоторая статистика $K_n(x_1, x_2, \dots, x_n)$, закон распределения которой известен в предположении, что гипотеза H_0 истинна.

По статистике критерия $K_n(x_1, x_2, \dots, x_n)$ и заданному уровню значимости множество вещественных чисел разбивают на две части, одну из них – $\Omega_{\text{крит.}}$ называют *критической областью*, другую – Ω называют областью принятия гипотезы.

Критическая область может быть односторонней (правосторонней или левосторонней) (рис. 2.1.1). В этом случае критерий согласия называется *односторонним*.




Рис. 2.1.1

Для определения односторонней критической области достаточно найти критическую точку $t_{\text{ед}}$ – квантиль – разделяющий области Ω и $\Omega_{\text{крит.}}$.

Если критическая область правосторонняя, то квантиль $t_{\text{кр}}$ определяется из соотношения

$$P\{K_n > t_{\text{кр}}\} = \alpha.$$

Если критическая область левосторонняя, то квантиль $t_{\text{кр}}$ определяется из соотношения

$$P\{K_n < t_{\text{кр}}\} = \alpha.$$

Критическая область может быть двусторонней (рис. 2.1.2). В этом случае критерий называется *двусторонним*.




Рис. 2.1.2.

Если критическая область двусторонняя, то определяют два квантиля: левый $t_{кр}^л$ и правый $t_{кр}^н$ из условия

$$P\{K_n < t_{кр}^л\} = P\{K_n > t_{кр}^н\} = \frac{\alpha}{2}.$$

Значения квантилей обычно определяют из статистических таблиц: таблицы квантилей распределения χ^2 или таблицы квантилей распределения Стьюдента, и.т.д. в зависимости от того, какая статистика используется в выбранном критерии согласия.

Гипотеза H_0 принимается, если $K \in \Omega$. Гипотеза H_0 отвергается, если $K \in \Omega_{крит.}$

ЗАМЕЧАНИЕ

При разбиении множества вещественных чисел на критическую область $\Omega_{крит.}$ и область принятия гипотезы Ω должны выполняться два требования:

1. если проверяемая гипотеза H_0 верна, то $p(K \in \Omega_{крит.}) \leq \alpha$;
2. если проверяемая гипотеза H_0 не верна, то $p(K \in \Omega_{крит.})$ принимает максимально возможное значение (этим требование иногда приходится пренебрегать).

2.2. Проверка гипотезы о законе распределения случайной величины X на основе критерия Пирсона

2.2.1. Критерий Пирсона

На практике часто используется критерий χ^2 – Пирсона. При использовании критерия Пирсона выбирают статистику $\chi_n^2(x_1, x_2, \dots, x_n)$, равную сумме квадратов отклонений статистических вероятностей w_i от гипотетических p_i при $i = 1, 2, \dots, l$, где l – число интервалов группированного ряда. Эта сумма квадратов берется с некоторыми весами c_i , $i = 1, 2, \dots, l$, т.е.

$$\chi_n^2(x_1, x_2, \dots, x_n) = \sum_{i=1}^n c_i (w_i - p_i)^2.$$

Гипотетическая вероятность p_i – это вероятность попадания выборочной случайной величины в i – й интервал группированного (интервального) ряда при условии, что генеральная случайная величина X распределена по закону, сформулированному в проверяемой гипотезе.

Веса c_i вводятся таким образом, чтобы при одних и тех же отклонениях $(w_i - p_i)^2$ больший вес имели отклонения, при которых вероятность p_i была мала, и меньший вес – при которых вероятность p_i – велика. Следуя этим соображениям c_i выбраны обратно пропорциональными

вероятностям p_i , т.е. $c_i = \frac{n}{p_i}$, где n – объем выборки. Можно доказать, что, при $n \rightarrow \infty$ статистика

$$\chi_n^2 = \sum_{i=1}^l \frac{n}{p_i} (w_i - p_i)^2, \quad (2.2.1)$$

или

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i} \quad (2.2.2)$$

имеет " χ^2 – распределение" с $m = l - r - 1$ степенями свободы, где l – число интервалов группированного ряда, r – число параметров теоретического распределения, вычисленных по экспериментальным данным.

Числа $n_i = nw_i$ и np_i называются соответственно *эмпирическими и теоретическими частотами*.

3.2.2. Схема применения критерия χ^2 для проверки гипотезы H_0

1. По данным выборки строится статистический группированный (интервальный) ряд.
2. По выборочным данным определяется наблюдаемая величина статистики

$$\chi_{набл}^2 = \sum_{i=1}^l \frac{(n_i - np_i)^2}{np_i}. \quad (2.2.3)$$

3. Для выбранного уровня значимости α по таблице квантилей распределения χ^2 находится критическое значение $\chi_{ед}^2 = \chi_{\alpha, m}^2$ при числе степеней свободы $m = l - r - 1$.

4. Учитывая вид плотности распределения χ^2 (рис. 2.2.1), критическая область выбирается односторонней (правосторонней).

5. Если наблюдаемое значение χ^2 больше критического т.е. $\chi_{набл}^2 > \chi_{кр}^2$, то гипотеза H_0 отвергается. Если $\chi_{набл}^2 \leq \chi_{кр}^2$, то считают, что гипотеза H_0 не противоречит опытным данным.

ЗАМЕЧАНИЕ 1

Иногда для проверки истинности основной гипотезы по критерию Пирсона строят двустороннюю критическую область. Областью принятия выдвинутой гипотезы будет область, заданная неравенствами

$$\chi_{1-\alpha; m}^2 \leq \chi^2 \leq \chi_{\alpha; m}^2,$$

где $\chi_{1-\alpha; m}^2$ определяется по той же таблице. В этом случае основная гипотеза отвергается, если

$$\chi_{набл}^2 < \chi_{1-\alpha; m}^2 \text{ или } \chi_{набл}^2 \leq \chi_{\alpha; m}^2$$

ЗАМЕЧАНИЕ 2

При использовании критерия Пирсона следует иметь в виду, что статистика

$$\chi^2 = \sum_{i=1}^l \frac{(n_i - np_i)^2}{np_i}$$

распределена по закону χ^2 при $n \rightarrow \infty$. Поэтому необходимо, чтобы в каждом интервале группированного ряда было достаточное количество наблюдений, по крайней мере 5. Если в каком-нибудь интервале число наблюдений $n_i < 5$, следует объединить его с одним из соседних интервалов, сложив соответствующие частоты.

Пример 2.2.1

Для эмпирического распределения случайной величины X , заданного в виде группированного статистического ряда в табл. 2.2.1, проверить гипотезу о нормальном распределении генеральной совокупности при уровне значимости $\alpha = 0,05$ с помощью критерия Пирсона.

Таблица 2.2.1

N	Интервалы	n_i	w_i	$\sum_{j<i} n_j$	$\sum_{j<i} w_j$
1	94,0-100,0	3	0,03	3	0,03
2	100,0-106,0	7	0,07	10	0,10
3	106,0-112,0	11	0,11	21	0,21
4	112,0-118,0	20	0,20	41	0,41
5	118,0-124,0	28	0,28	69	0,69
6	124,0-130,0	19	0,19	88	0,88
7	130,0-136,0	10	0,10	98	0,98
8	136,0-142,0	2	0,02	100	1,00
Σ		100	1,00	—	—

Решение

Построим гистограмму относительных частот w_i . По виду этой кривой (рис. 2.2.1) можно предположить нормальный закон распределения генеральной случайной величины X .




Рис. 2.2.1

Площадь под кривой почти в 6 раз превышает единицу, так как вместо плотности относительной частоты $\frac{w_i}{h}$ по вертикали отложена относительная частота w_i .

Параметры нормального закона $m = M[X]$ и σ^2 , являющиеся соответственно математическим ожиданием и дисперсией случайной величины X , неизвестны, поэтому заменим их статистиками – несмещенными и состоятельными оценками соответственно выборочной средней $m = \bar{x}$ и выборочной дисперсией $\sigma^2 = \bar{s}^2$ и вычислим их, используя выборочные данные в таблице 2.2.1.

$$\bar{x} = 119,2, \quad \bar{s}^2 = 87,48, \quad \bar{s} = 9,35.$$

Основная гипотеза H_0 : генеральная случайная величина X распределена нормально с параметрами $m = \bar{x} = 119,2$, $\sigma^2 = \bar{s}^2 = 87,48$.

Кривая теоретической плотности распределения с поправочным коэффициентом $\Delta = 6,0$, тем же, что и у гистограммы, тоже изображена на рис. 2.2.1.

Вероятности p_i , т.е. вероятности попадания случайной величины X в полуинтервалы $[x_{i-1}, x_i)$ вычисляются в соответствии со свойством функции распределения нормального закона через функцию Лапласа $\Phi(x)$ по формуле

$$p_i = P\{x_{i-1} \leq X \leq x_i\} = \Phi\left(\frac{x_i - m}{\sigma}\right) - \Phi\left(\frac{x_{i-1} - m}{\sigma}\right),$$

или, при замене параметров распределения средним выборочным и выборочной дисперсией, по приближенной формуле

$$p_i \approx \Phi\left(\frac{x_i - 119.2}{9.35}\right) - \Phi\left(\frac{x_{i-1} - 119.2}{9.35}\right).$$

По вычисленным вероятностям p_i , $i = 1, 2, \dots, l$ определяют теоретические частоты np_i , а затем по формуле (2.2.3) наблюдаемое значение статистики $\chi^2_{набл}$. Все вычисления удобно внести в таблицу (табл. 2.2.2).

В последнем столбце таблицы помещены значения $\varphi_i = \frac{(n_i - np_i)^2}{np_i}$, так, что $\chi^2_{набл} = \sum_{i=1}^l \varphi_i$.

При вычислении значения критерия Пирсона χ^2 частоты первого и последнего интервалов оказались меньше 5. Поэтому эти интервалы были объединены с соседними. Число интервалов при этом уменьшилось. Новое число интервалов $l = 6$.

Нормальный закон распределения определяется двумя параметрами. Поэтому число степеней свободы определяется формулой

$$m = l - r - 1 = 6 - 2 - 1 = 3.$$

Таблица 2.2.2

i	Интервалы $[x_{i-1}, x_i]$	n_i	p_i	np_i	$(n_i - np_i)^2$	φ_i
1	94-100	3	0,017	1,7	5,76	0,758
2	100-106	7	0,059	5,9		
3	106-112	11	0,141	14,1	9,61	0,682
4	112-118	20	0,228	22,8	7,84	0,344
5	118-124	28	0,247	24,7	10,89	0,441
6	124-130	19	0,182	18,2	0,64	0,035
7	130-136	10	0,087	8,7	0,16	0,014
8	136-142	2	0,029	2,9		
Σ		100	0,99	99	—	2,27

Из таблицы ясно, что $\chi^2_{набл} = \sum_{i=1}^l \varphi_i = 2,27$.

По заданному значению уровня значимости α и вычисленному числу степеней свободы m из таблицы распределения χ^2 (табл. 5.3) вычисляют квантиль $\chi^2_{кр} = 7,82$, который определяет границу критической области $(7,82; +\infty)$

Поскольку

$$\chi^2_{набл} = 2,27 < \chi^2_{кр} = 7,82,$$

то наблюдаемое значение статистики попадает в область принятия гипотезы. Гипотеза о выбранном теоретическом нормальном законе распределения с параметрами $m = 119,2$,

$\sigma^2 = 87,48$ для генеральной случайной величины X согласуется с опытными данными и она принимается.

3. Регрессионный анализ

3.1. Эмпирическая (выборочная) регрессия

3.1.1. Двумерная случайная выборка. Корреляционное поле. Выборочный случайный вектор

Две случайные величины могут быть:

- независимыми;
- связаны функциональной зависимостью, когда каждому значению одной соответствует вполне *определенное* значение другой;
- связаны зависимостью, называемой *стохастической*, когда каждому значению одной соответствует *определенное (условное) распределение* другой.

В частности, стохастическая зависимость между значениями одной из них и условным математическим ожиданием другой, называется *корреляционной*.

Корреляционная зависимость между случайными величинами X и Y характеризуется «поведением» случайных величин $M(X/Y)$ и $M(Y/X)$ – условных математических ожиданий, которые принимают значения:

$$M(X/Y = y) = m_X(y), \quad M(Y/X = x) = m_Y(x)$$

соответственно.

Для отыскания модельных уравнений регрессии, вообще говоря, необходимо знать закон распределения двумерной случайной величины (случайного вектора) (X, Y) . Если закон распределения (X, Y) не известен, а известна лишь выборка пар значений (x, y) – *двумерная случайная выборка*, то речь может идти только об оценке (приближенном выражении) функций регрессии по выборке.

Приближенные выражения функций регрессии находят *методом наименьших квадратов*, используя то, что математическое ожидание

$$M[Y - g(X)]^2$$

принимает наименьшее значение, если $g(x) = m_Y(x)$.

Полученные методом наименьших квадратов функции $g(x)$ могут не совпадать с модельными функциями регрессии. Они называются функциями *средней квадратической регрессии*. Если в качестве функций $g(x)$ выбираются линейные функции $g(x) = ax + b$, то их называют функциями *линейной средней квадратической регрессии*.

Функции средней квадратической регрессии, найденные для выборочного случайного вектора, называются функциями *выборочной (эмпирической) регрессии*.

Пусть в результате n независимых экспериментов получено n пар значений случайных величин X и Y .

Определение 3.1.1

Множество пар значений случайных величин X и Y

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n), \quad (3.1.1)$$

полученных в результате n независимых экспериментов, называется *двумерной случайной выборкой*.

Определение 3.1.2

Если каждой паре значений двумерной случайной выборки поставлено в соответствие вероятность $\frac{1}{n}$ ее реализации, то множество (x_i, y_i) для всех $(i = 1, 2, \dots, n)$ называют *двумерным выборочным случайным вектором*.

Выборочный случайный вектор является дискретным. Его закон распределения может быть записан в виде таблицы 3.1.1.

Таблица 3.1.1

	y_1	y_2		y_n
x_1	$\frac{1}{n}$	0		0
x_2	0	$\frac{1}{n}$		0
.....				
x_n	0	0	0	$\frac{1}{n}$

Декартова плоскость с нанесенными на нее точками с координатами из равенств (3.1.1) называется *корреляционным полем* (рис. 3.1.1).




Рис. 3.1.1

По виду корреляционного поля иногда можно судить о виде зависимости между случайными величинами X и Y , если такая существует.

ЗАМЕЧАНИЕ

Следует иметь в виду, что если между случайными величинами X и Y есть зависимость, то не всегда она является функциональной, т.е. не всегда существует неслучайная функция φ , такая, что $Y = \varphi(X)$. Иногда эта зависимость является стохастической, т.е. эта зависимость также является случайной функцией.

3.1.2. Функции и кривые регрессии

Определения функций и линий регрессии давались ранее. Напомним их в данном разделе.

Определение 3.1.3

Если $(X, Y)^T$ – двумерный случайный вектор, то условное математическое ожидание $M\left[X/Y=y\right]$ обозначается $m_X(y)$ и называется *функцией регрессии (модельной или 1 рода) случайной величины X на случайную величину Y* .

Определение 3.1.4

Если $(X, Y)^T$ – двумерный случайный вектор, то условное математическое ожидание $M\left[Y/X=x\right]$ обозначается $m_Y(x)$ и называется *функцией регрессии (модельной или 1 рода) случайной величины Y на случайную величину X* .

Определение 3.1.5

Уравнения $x = m_X(y)$ и $y = m_Y(x)$ называются уравнениями *линий регрессии*.

Определение 3.1.6

Если линии регрессии – прямые линии, то регрессия называется *линейной*, а функции $m_X(y)$ и $m_Y(x)$ – *модельными функциями линейной регрессии*.

ЗАМЕЧАНИЕ 1

Функция регрессии $m_X(y)$ показывает изменение «в среднем» случайной величины X в зависимости от изменения случайной величины Y . Аналогичный смысл имеет и функция регрессии $m_Y(x)$.

Теорема 3.1.1

Функции регрессии минимизируют математическое ожидание квадрата отклонения случайной величины X от произвольной функции $\psi(Y)$ случайной величины Y и квадрата отклонения случайной величины Y от произвольной функции $\varphi(X)$ случайной величины X , т.е.

$$M[X - \psi(Y)]^2 \quad (3.1.2)$$

принимает наименьшее значение, если $\psi(y) = m_X(y)$, а

$$M[Y - \varphi(X)]^2 \quad (3.1.3)$$

принимает наименьшее значение, если $\varphi(x) = m_Y(x)$.

ЗАМЕЧАНИЕ 2

Из теоремы, доказательство которой мы опускаем, следует, что функция регрессии $m_X(y)$ дает наилучшую аппроксимацию случайной величины X в зависимости от случайной величины Y , т.е. $X \approx \psi(Y)$, а функция регрессии $m_Y(x)$ – наилучшую аппроксимацию случайной величины Y в зависимости от случайной величины X , т.е. $Y \approx \varphi(X)$.

ЗАМЕЧАНИЕ 3

Геометрически минимизация математического ожидания (3.1.2) и (3.1.3) это минимизация суммы квадратов расстояний между ординатами – значениями случайных величин Y и $\varphi(X)$ при всех возможных значениях X (сумма квадратов расстояний $A_i B_i$ на рис. 3.1.2).




Рис. 3.1.2

Модельные функции регрессии можно найти точно, если задан закон распределения случайного вектора. Если необходимо найти функции и линии регрессии, основываясь на выборочных данных, то для минимизации математического ожидания (3.1.2) и (3.1.3) пользуются *методом наименьших квадратов*. При этом необходимо ограничиться каким-то определенным классом этих функций, например, считая их линейными или квадратичными, и т.д. Полученные функции $\varphi(X)$ и $\psi(Y)$, минимизирующие математическое ожидание, могут не совпадать с функциями регрессии. Поэтому их называют *функциями средней квадратичной регрессии*.

3.2. Линейная регрессия

3.2.1. Линейная регрессия. Коэффициенты и линии линейной регрессии

Если при построении наилучшего приближения к случайной величине Y , выбирается в качестве функции $\varphi(X)$ линейная функция $aX + b$, то ее называют *линейной функцией средней*

квадратичной регрессии (модельной или 1 рода). Графиком этой функции является прямая, которую называют *прямой средней квадратичной регрессии*.

Теорема 3.2.1

Уравнение прямой средней квадратичной регрессии случайной величины Y на X имеет вид

$$\frac{y - M[Y]}{\sigma_Y} = r_{XY} \frac{x - M[X]}{\sigma_X}, \quad (3.2.1)$$

где σ_X и σ_Y – средние квадратичные отклонения случайных величин X и Y соответственно; r_{XY} – коэффициент корреляции.

Уравнение прямой средней квадратичной регрессии случайной величины X на Y имеет вид

$$\frac{y - M[Y]}{\sigma_Y} = \frac{1}{r_{XY}} \cdot \frac{x - M[X]}{\sigma_X}. \quad (3.2.2)$$

Доказательство

Подставим в выражение (3.2.2) $\varphi(X) = aX + b$ и обозначим полученную функцию двух параметров a и b через $F(a, b)$. Полученное для функции $F(a, b)$ выражение

$$F(a, b) = M[Y - (aX + b)]^2$$

преобразуем, используя свойства дисперсии.

$$\begin{aligned} F(a, b) &= D[Y - (aX + b)] + (M[Y - (aX + b)])^2 = \\ &= D[Y] + a^2 D[X] - 2aK_{XY} + (M[Y] - aM[X] - b)^2. \end{aligned}$$

Параметры a и b должны быть выбраны так, чтобы функция $F(a, b)$ принимала наименьшее значение. Для исследования на экстремум функции $F(a, b)$ вычислим ее стационарную точку.

$$\begin{cases} \frac{\partial F(a, b)}{\partial a} = 2aD[X] - 2K_{XY} + 2(M[Y] - aM[X] - b)(-M[X]) = 0 \\ \frac{\partial F(a, b)}{\partial b} = -2(M[Y] - aM[X] - b)(-M[X]) = 0 \end{cases}.$$

Из второго уравнения полученной системы следует, что $M[Y] - aM[X] - b = 0$. Учитывая это в первом уравнении и разделив его на два, получим равносильную систему

$$\begin{cases} aD[X] - K_{XY} = 0 \\ M[Y] - aM[X] - b = 0 \end{cases},$$

из которой легко определяются параметры

$$a = \frac{K_{XY}}{D[X]} = r_{XY} \cdot \frac{\sigma_Y}{\sigma_X}, \quad b = M[Y] - r_{XY} \cdot \frac{\sigma_Y}{\sigma_X} \cdot M[X]. \quad (3.2.3)$$

В полученных формулах для коэффициентов a и b через K_{XY} обозначен корреляционный момент, а через r_{XY} – коэффициент корреляции.

Исследуем на экстремум с помощью частных производных второго порядка стационарную точку, определяемую соотношениями (3.2.3).

$$\begin{cases} \frac{\partial^2 F(a, b)}{\partial a^2} = 2D[X] + 2(M[X])^2 = A > 0 \\ \frac{\partial^2 F(a, b)}{\partial a \partial b} = 2M[X] = B \\ \frac{\partial^2 F(a, b)}{\partial b^2} = 2 = C > 0 \end{cases}.$$

Поскольку дискриминант

$$\Delta = AC - B^2 = 4D[X] + 4(M[X])^2 - 4(M[X])^2 = 4D[X] > 0$$

положительный, то в стационарной точке есть экстремум, а так как $A > 0$ и $C > 0$, то этот экстремум – минимум.

Используя формулы (3.2.3) для найденных коэффициентов линейной функции $Y = \varphi(X) = aX + b$ получим линейную функцию средней квадратичной регрессии

$$y = r_{XY} \cdot \frac{\sigma_Y}{\sigma_X} \cdot x + M[Y] - r_{XY} \cdot \frac{\sigma_Y}{\sigma_X} \cdot M[X],$$

или

$$y = M[Y] - a_{Y/X} \cdot (M[X] - x), \quad (3.2.4)$$

где число

$$a_{Y/X} = r_{XY} \cdot \frac{\sigma_Y}{\sigma_X} \quad (3.2.5)$$

называется *коэффициентом регрессии Y на X* .

Графиком линейной функции средней квадратичной регрессии (3.2.4) является прямая средней квадратичной регрессии. Уравнение (3.2.4) можно записать также в виде:

$$\frac{y - M[Y]}{\sigma_Y} = r_{XY} \frac{x - M[X]}{\sigma_X}.$$

Аналогично доказывается соотношение (3.2.2) для прямой средней квадратичной регрессии X на Y .

ЗАМЕЧАНИЕ 1

Из вида уравнений (3.2.1) и (3.2.2) прямых регрессии легко видеть, что они совпадают тогда и только тогда, когда случайные величины X и Y связаны линейной зависимостью, т.е. $r_{XY} = \pm 1$.

ЗАМЕЧАНИЕ 2

Если случайные величины X и Y независимы или некоррелированные, то прямые регрессии параллельны координатным осям.

3.2.2. Линейная эмпирическая (выборочная) регрессия

Пусть задана двумерная случайная выборка объема n из значений случайного вектора $(X, Y)^T$:

$$(x_1; y_1), (x_2; y_2), \dots, (x_n; y_n).$$

Если ставится вопрос об исследовании зависимости между случайными величинами X и Y на основе эмпирических данных, то строится корреляционное поле и по его виду определяется характер этой зависимости. Например, по построенному корреляционному полю на рис. 3.1.1 можно предположить, что эта зависимость линейная, т.е. $Y = aX + b$.

Чтобы получить эмпирические (выборочные) уравнения прямых средней квадратичной регрессии Y на X и X на Y , нужно в уравнениях (3.2.1) и (3.2.2) заменить все генеральные моменты выборочными, т.е.

- математические ожидания $M[X]$ и $M[Y]$ заменить средними выборочными

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{и} \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i;$$

- средние квадратичные отклонения σ_X и σ_Y заменить выборочными

$$s_X = \sqrt{x^2 - (\bar{x})^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2 - (\bar{x})^2} \quad \text{и} \quad s_Y = \sqrt{y^2 - (\bar{y})^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n y_i^2 - (\bar{y})^2} \quad \text{или исправленными}$$

$$\text{выборочными средними квадратичными отклонениями } \bar{s}_X = \sqrt{\frac{n}{n-1}} s_X \quad \text{и} \quad \bar{s}_Y = \sqrt{\frac{n}{n-1}} s_Y;$$

- для выборочного коэффициента корреляции использовать статистику

$$r_{XY}^* = \frac{K_{XY}^*}{s_X \cdot s_Y} = \frac{\frac{1}{n} \sum_{i=1}^n x_i \cdot y_i - \bar{x} \cdot \bar{y}}{s_X \cdot s_Y}.$$

Эмпирическое уравнение прямой средней квадратичной регрессии случайной величины Y на X примет вид:

$$\frac{y - \bar{y}}{s_Y} = r_{XY}^* \frac{x - \bar{x}}{s_X}. \quad (3.2.6)$$

Эмпирическое уравнение прямой средней квадратичной регрессии случайной величины X на Y запишется в виде:

$$\frac{y - \bar{y}}{s_Y} = \frac{1}{r_{XY}^*} \frac{x - \bar{x}}{s_X}. \quad (3.2.7)$$

Выражая из уравнения (3.2.6) y через x , а из (3.2.7) – x через y , получим эмпирические (выборочные) функции регрессии или функции регрессии 2 рода Y на X и X на Y соответственно.

$$y = \bar{y} + a_{Y/X}^* (x - \bar{x}), \quad (3.2.8)$$

$$x = \bar{x} + a_{X/Y}^* (y - \bar{y}), \quad (3.2.9)$$

в которых

$$a_{Y/X}^* = r_{YX}^* \cdot \frac{s_Y}{s_X} \text{ – выборочный коэффициент регрессии } Y \text{ на } X,$$

$$a_{X/Y}^* = r_{XY}^* \cdot \frac{s_X}{s_Y} \text{ – выборочный коэффициент регрессии } X \text{ на } Y.$$

ЗАМЕЧАНИЕ

Очевидно, что прямые регрессии, заданные уравнениями (3.2.8) и (3.2.9) пересекаются в точке $(\bar{x}; \bar{y})$.

Пример 3.2.1

Задана двумерная выборка из генеральной совокупности $(X, Y)^T$:

$$(1; 3), (2; 5), (-1; 2), (0; 3), (0; 2).$$

Построить эмпирические функции регрессии Y на X и X на Y .

Решение

Вычислим выборочные моменты:

$$\bar{x} = \frac{1+2-1+0+0}{5} = 0,4, \quad \bar{y} = \frac{3+5+2+3+2}{5} = 3,$$

$$s_X^2 = \frac{1^2+2^2+1^2+0+0}{5} - 0,4^2 = 1,04, \quad s_Y^2 = \frac{3^2+5^2+2^2+3^2+2^2}{5} - 3^2 = 1,2,$$

$$s_X \approx 1,02, \quad s_Y \approx 1,1.$$

Тогда выборочный коэффициент корреляции равен:

$$\begin{aligned} r_{XY}^* &= \frac{\frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \cdot \bar{y}}{s_X \cdot s_Y} = \\ &= \frac{\frac{1}{5}(1 \cdot 3 + 2 \cdot 5 + (-1) \cdot 2 + 0 \cdot 3 + 0 \cdot 2) - 0,4 \cdot 3}{1,02 \cdot 1,1} \approx 0,89. \end{aligned}$$

Вычислим выборочные коэффициенты регрессии:

$$a^*_{Y/X} = r^*_{YX} \cdot \frac{s_Y}{s_X} = 0,89 \cdot \frac{1,1}{1,02} \approx 0,96, \quad a^*_{X/Y} = r^*_{XY} \cdot \frac{s_X}{s_Y} = 0,89 \cdot \frac{1,1}{1,02} \approx 0,83.$$

Используя формулы (3.2.8) и (3.2.9), запишем функции регрессии 2 рода

$$y = 3 + 0,96(x - 0,4), \quad x = 0,4 + 0,83(y - 3).$$

После элементарных преобразований получим:

$$y = 0,96x + 2,616, \quad x = 0,83y - 2,09. \quad (3.2.10)$$

Построим корреляционное поле и прямые, заданные уравнениями (3.2.10) (рис. 3.2.1). Из рисунка видно, что эти прямые пересекаются в точке $(\bar{x}; \bar{y}) = (0,4; 3)$ и почти сливаются. Следовательно, зависимость между случайными величинами X и Y близка к линейной зависимости. То, что зависимость между случайными величинами X и Y близка к линейной, ясно из величины выборочного коэффициента корреляции $r^*_{XY} \approx 0,89$, который близок к единице.




Рис. 3.2.1

3.2.3. Значимость оценки линейной выборочной регрессии и параметров регрессии

Доверительный интервал для функции регрессии

Рассмотрим эмпирическую линейную регрессию Y на X . Из (3.2.8) следует, что ее уравнение имеет вид:

$$\bar{y}_x = b_1 \cdot x + b_0, \quad (3.2.10)$$

$$\text{где } b_1 = \rho^*_{\eta/\xi}, \quad b_0 = \bar{y} - \rho^*_{\eta/\xi} \cdot \bar{x}.$$

В силу воздействия неучтенных случайных факторов и причин отдельные наблюдения $\bar{y}_x$ случайной величины Y будут в большей или меньшей степени отклоняться от функции регрессии. Это означает, что каждому наблюдению y_i соответствует функциональная зависимость вида:

$$y_i = \beta_1 x_i + \beta_0 + \varepsilon_i, \quad i = 1, 2, \dots, n, \quad (3.2.11)$$

где $\beta_1 x_i + \beta_0 = M[Y/X = x_i]$ – неслучайная часть, ε_i – случайная часть.

Величина несмещенной дисперсии

$$\bar{s}^2 = \frac{\sum_{i=1}^n (\bar{y}_x(x_i) - y_i)^2}{n - 2}, \quad (3.2.12)$$

где число степеней свободы $n - 2$ (два оцениваемых параметра β_1 и β_0 в уравнении 3.2.12) характеризует среднеквадратичный разброс значений y_i относительно линии выборочной регрессии. В этом разделе выясняется: являются ли оценки $\bar{y}_x$ и b_1 наилучшими для функции регрессии и параметра β_1 ?

Будем полагать, что:

- 1) в (3.2.11) ε_i и y_i – случайные величины, а x_i – неслучайная величина;
- 2) ε_i являются некоррелированными случайными величинами, то есть $\text{cov}(\varepsilon_i; \varepsilon_j) = 0, i \neq j$;
- 3) математические ожидания $M[\varepsilon_i] = 0$ при всех $i \Rightarrow M[y_i] = \beta_1 x_i + \beta_0$;
- 4) дисперсии $D[\varepsilon_i] = \sigma^2 \Rightarrow D[y_i] = \sigma^2$ – постоянные при всех i ;
- 5) ε_i , а следовательно, и y_i распределены по нормальному закону.

Предположения 1–5 называются *основными предпосылками* регрессионного анализа или условиями Гаусса–Маркова, а (3.2.11) в таких предположениях – *классической нормальной линейной регрессионной моделью*.

Стандартная ошибка эмпирической функции линейной регрессии $\bar{y}_x$ обозначается $s_{\bar{y}_x} = \sqrt{s_{\bar{y}_x}^2}$ и вычисляется по формуле

$$s_{\bar{y}_x}^2 = \bar{s}^2 \cdot \left(\frac{1}{n} + \frac{(x - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right), \quad (3.2.13)$$

в которой несмещенная дисперсия $\bar{s}^2$ вычисляется по формуле (3.2.12).

Поскольку в силу предпосылок регрессионного анализа наблюдения y_i распределены нормально с математическим ожиданием $\beta_1 x + \beta_0$, зависящим от x , и конечной дисперсией σ^2 , то статистика

$$\tau_{n-2} = \frac{\bar{y}_x - m_Y(x)}{s_{\bar{y}_x}}$$

где $m_Y(x)$ – функция регрессии генеральной случайной величины Y на X ;

$\bar{y}_x = b_1 \cdot x + b_0$ – выборочная функция линейной регрессии Y на X ;

Выборочная функция линейной регрессии $\bar{y}_x = b_1 \cdot x + b_0$ имеет распределение Стьюдента с $n-2$ степенями свободы. Поэтому, если из таблицы распределения Стьюдента (табл. 5.4) определяется квантиль $t_{n-2, \alpha}$, такой, что $P\{|\tau_{n-2}| < t_{n-2, \beta}\} = \beta$, а из неравенства $|\tau_{n-2}| < t_{n-2, \beta}$ следует неравенство для доверительного интервала функции регрессии $m_Y(x)$, в любой точке x :

$$\bar{y}_x(x) - t_{n-2, \alpha} \cdot s_{\bar{y}_x} < m_Y(x) < \bar{y}_x(x) + t_{n-2, \alpha} \cdot s_{\bar{y}_x}. \quad (3.2.14)$$

Величина доверительного интервала зависит от значений x , причем минимальный доверительный интервал соответствует значению $x = \bar{x}$ ($\bar{x}$ – среднее выборочное генеральной случайной величины X). Доверительный интервал возрастает при удалении от этой точки. Таким образом, прогноз значений по уравнению регрессии оправдан вблизи точки $x = \bar{x}$.

Доверительный интервал для коэффициента регрессии

При сделанных предпосылках регрессионного анализа, можно построить доверительный интервал для параметра β_1 в классической нормальной линейной регрессионной модели (3.2.11).

Если сделаны предположения регрессионного анализа 1 – 5, то статистика

$$\tau_{n-2} = \frac{b_1 - \beta_1}{\bar{s}_{\eta}} \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}$$

имеет распределение Стьюдента с $n-2$ степенями свободы. Если по заданной надежности β и числу степеней свободы $n-2$ вычислить $t_{n-2,\beta}$ по таблице распределения Стьюдента (табл. 5.4) то из неравенства

$$|\tau_{n-2}| < t_{n-2,\beta}$$

следует вид доверительного интервала для параметра β_1 :

$$b_1 - t_{n-2,\beta} \cdot \frac{\bar{s}}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}} \leq \beta_1 \leq b_1 + t_{n-2,\beta} \cdot \frac{\bar{s}}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}. \quad (3.2.15)$$

4. Рекомендуемая литература

Основная литература

1. Л. Г. Бирюкова, Г.И. Бобрик, В.И. Ермаков Теория вероятностей и математическая статистика. Учебное пособие. – М.: Инфра. 2004.
2. Гмурман В.Е. Теория вероятностей и математическая статистика. М., Высшая школа, 2000.
3. Гмурман В.Е. Руководство к решению задач по теории вероятностей и математической статистике. М., Высшая школа, 2003.

Дополнительная литература

4. Д.М. Письменный. Конспект лекций по теории вероятностей, математической статистике и случайным процессам. М.: Айрис, 2006.

5.1. Таблица значений функции $\varphi(x)$

Таблица 5.1.

	0	1	2	3	4	5	6	7	8	9
0,0	0,3989	0,3989	0,3989	0,3988	0,3986	0,3984	0,3982	0,3980	0,3977	0,3973
0,1	0,3970	0,3965	0,3961	0,3956	0,3951	0,3945	0,3939	0,3932	0,3925	0,3918
0,2	0,3910	0,3902	0,3894	0,3885	0,3876	0,3867	0,3857	0,3847	0,3836	0,3825
0,3	0,3814	0,3802	0,3790	0,3778	0,3765	0,3752	0,3739	0,3726	0,3712	0,3697
0,4	0,3683	0,3668	0,3652	0,2637	0,3621	0,3605	0,3589	0,3572	0,3555	0,3538
0,5	0,3521	0,3503	0,3485	0,3467	0,3448	0,3429	0,3410	0,3391	0,3372	0,3352
0,6	0,3332	0,3312	0,3292	0,3271	0,3251	0,3230	0,3209	0,3187	0,3166	0,3144
0,7	0,3123	0,3101	0,3079	0,3056	0,3034	0,3011	0,2989	0,2966	0,2943	0,2920
0,8	0,2897	0,2874	0,2850	0,2827	0,2803	0,2780	0,2756	0,2732	0,2709	0,2685
0,9	0,2661	0,2637	0,2613	0,2589	0,2565	0,2541	0,2516	0,2492	0,2468	0,2444
1,0	0,2420	0,2396	0,2371	0,2347	0,2323	0,2299	0,2275	0,2251	0,2227	0,2203
1,1	0,2179	0,2155	0,2131	0,2107	0,2083	0,2059	0,2036	0,2012	0,1989	0,1965
1,2	0,1942	0,1919	0,1895	0,1872	0,1849	0,1826	0,1804	0,1781	0,1738	0,1736
1,3	0,1714	0,1691	0,1669	0,1647	0,1626	0,1604	0,1582	0,1561	0,1569	0,1518
1,4	0,1497	0,1476	0,1456	0,1435	0,1415	0,1394	0,1374	0,1354	0,1334	0,1315
1,5	0,1295	0,1276	0,1257	0,1238	0,1219	0,1200	0,1182	0,1163	0,1145	0,1127
1,6	0,1109	0,1092	0,1074	0,1057	0,1040	0,1023	0,1006	0,0989	0,0973	0,0957
1,7	0,0940	0,0925	0,0909	0,0893	0,0878	0,0863	0,0848	0,0833	0,0818	0,0804
1,8	0,0790	0,0775	0,0761	0,0748	0,0734	0,0721	0,0707	0,0694	0,0681	0,0669
1,9	0,0656	0,0644	0,0632	0,0620	0,0608	0,0596	0,0584	0,0573	0,0562	0,0551
2,0	0,0540	0,0529	0,0519	0,0508	0,0498	0,0488	0,0478	0,0468	0,0459	0,0449
2,1	0,0440	0,0431	0,0422	0,0413	0,0404	0,0396	0,0387	0,0379	0,0371	0,0363
2,2	0,0355	0,0347	0,0339	0,0332	0,0325	0,0317	0,0310	0,0303	0,0297	0,0290
2,3	0,0283	0,0277	0,0270	0,0264	0,0258	0,0252	0,0246	0,0241	0,0235	0,0229
2,4	0,0224	0,0219	0,0213	0,0208	0,0203	0,0198	0,0194	0,0189	0,0184	0,0180
2,5	0,0175	0,0171	0,0167	0,0163	0,0158	0,0154	0,0151	0,0147	0,0143	0,0139
2,6	0,0136	0,0132	0,0129	0,0126	0,0122	0,0119	0,0116	0,0113	0,0110	0,0107
2,7	0,0104	0,0101	0,0099	0,0096	0,0093	0,0091	0,0088	0,0086	0,0084	0,0081
2,8	0,0079	0,0077	0,0075	0,0073	0,0071	0,0069	0,0067	0,0065	0,0063	0,0061
2,9	0,0060	0,0058	0,0056	0,0055	0,0053	0,0051	0,00501	0,0048	0,0047	0,0043
3,0	0,0044	0,0043	0,0042	0,0040	0,0039	0,0038	0,0037	0,0036	0,0035	0,0034
3,1	0,0033	0,0032	0,0031	0,0030	0,0029	0,0028	0,0027	0,0026	0,0025	0,0025
3,2	0,0024	0,0023	0,0022	0,0022	0,0021	0,0020	0,0020	0,0019	0,0018	0,0018

5.2. Таблица значений функции Лапласа

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_0^x e^{-\frac{t^2}{2}} dt$$

Таблица 5.2.

	0	1	2	3	4	5	6	7	8	9
0,0	0,00000	00399	00798	01197	01595	01994	02392	02790	03188	03586
0,1	03983	04380	04776	05172	05567	05962	06356	06749	07142	07535
0,2	07926	08317	08706	09095	09483	09871	10257	10642	11026	11409
0,3	11791	12172	12552	12930	13307	13683	14058	14431	14803	15173
0,4	15542	15910	16276	16640	17003	17364	17724	18082	18439	18793
0,5	19146	19497	19847	20194	20540	20884	21226	21566	21904	22240
0,6	22575	22907	23237	23565	23891	24215	24537	24857	25175	25490
0,7	25804	26115	26424	26730	27035	27337	27637	27935	28230	28524
0,8	28814	29103	29389	29673	29955	30234	30511	30785	31057	31327
0,9	31594	31859	32121	32381	32639	32894	33147	33398	33646	33891
1,0	34134	34375	34614	34850	35083	35314	35543	35769	35993	36214
1,1	36433	36650	36864	37076	37286	37493	37698	37900	38100	38298
1,2	38493	38686	38877	39065	39251	39435	39617	39796	39973	40147
1,3	40320	40490	40658	40824	40988	41149	41309	41466	41621	41774
1,4	41924	42073	42220	42364	42507	42647	42786	42922	43056	43189
1,5	43319	43448	43574	43699	43822	43943	44062	44179	44295	44408
1,6	44520	44630	44738	44845	44950	45053	45154	45254	45352	45449
1,7	45543	45637	45728	45818	45907	45994	46080	46164	46246	46327
1,8	46407	46485	46562	46638	46712	46784	46856	46926	46995	47062
1,9	47128	47193	47257	47320	47381	47441	47500	47558	47615	47670
2,0	47725	47778	47831	47882	47932	47982	48030	48077	48124	48169
2,1	48214	48257	48300	48341	48382	48422	48461	48500	48537	48574
2,2	48610	48645	48679	48713	48745	48778	48809	48840	48870	48899
2,3	48928	48956	48983	49010	49036	49061	49086	49111	49134	49158
2,4	49180	49202	49224	49245	49266	49286	49305	49324	49343	49361
2,5	49379	49396	49413	49430	49446	49461	49477	49492	49506	49520
2,6	49534	49547	49560	49573	49585	49598	49609	49621	49632	49643
2,7	49653	49664	49674	49683	49693	49702	49711	49720	49728	49736
2,8	49744	49752	49760	49767	49774	49781	49788	49795	49801	49807
2,9	49813	49819	49825	49831	49836	49841	49846	49851	49856	49861
3,0		0,49865		3,5		0,49977		4,0		0,499968
3,1		0,49903		3,6		0,49984		4,5		0,499997
3,2		0,49931		3,7		0,49989		5,0		0,49999997
3,3		0,49952		3,8		0,49993				
3,4		0,49966		3,9		0,49995				

5.3. Критические точки распределения χ^2

Значения $\chi^2_{m, \alpha}$ распределения χ^2 для числа степеней свободы m и вероятности

$$\alpha = P\{\chi^2_m > \chi^2_{m, \alpha}\}$$

Таблица 5.3.

$\alpha \backslash m$	0,01	0,025	0,05	0,95	0,975	0,99
1	6,6	5,0	3,8	0,0039	0,000981	0,00016
2	9,2	7,4	6,0	0,103	0,051	0,020
3	11,3	9,4	7,8	0,352	0,216	0,115
4	13,3	11,1	9,5	0,711	0,484	0,297
5	15,1	12,8	11,1	1,15	0,831	0,554
6	16,8	14,4	12,6	1,64	1,24	0,872
7	18,5	16,0	14,1	2,17	1,69	1,24
8	20,1	17,5	15,5	2,73	2,18	1,65
9	21,7	19,0	16,9	3,33	2,70	2,09
10	23,2	20,5	18,3	3,94	3,25	2,50
11	24,7	21,9	19,7	4,57	3,82	3,05
12	26,2	23,3	21,0	5,23	4,40	3,57
13	27,7	24,7	22,4	5,89	5,1	4,11
14	29,1	26,	23,7	6,57	5,63	4,66
15	30,6	27,5	25,0	7,26	6,26	5,23
16	32,0	28,	26,3	7,96	6,91	5,81
17	33,4	30,2	27,6	8,67	7,56	6,41
18	34,8	31,5	28,9	9,39	8,23	7,01
19	36,2	32,9	30,1	10,1	8,91	7,63
20	37,6	34,2	31,4	10,9	9,59	8,26
21	38,9	35,5	32,7	11,6	10,3	8,90
22	40,3	36,8	33,9	12,3	11,0	9,54
23	41,6	38,1	35,2	13,1	11,7	10,2
24	43,0	39,4	36,4	13,8	12,4	10,9
25	44,3	40,6	37,7	14,6	13,1	11,5
26	45,6	41,9	38,9	15,4	13,8	12,2
27	47,0	41.2	40,1	16,2	14,6	12,9
28	48,3	44,5	41,3	16,9	15,3	13,6
29	49,6	45,7	42,6	17,7	16,0	14,3
30	50,9	47,0	43,8	18,5	16,8	15,0
47	72,4	67,8	64,0	32,3	29,9	27,4
48	73,7	69,0	65,2	33,1	30,7	28,2

5.4. Критические точки распределения Стьюдента

Значения $t_{m,\beta}$ распределения Стьюдента для числа степеней свободы m и вероятности

$$\beta = P\{|t_m| < t_{m,\beta}\}$$

Таблица 5.4.

$\beta \backslash m$	0,1	0,05	0,02	0,01	0,002	0,001
1	6,31	12,7	31,82	63,7	318,3	637,0
2	2,92	4,30	6,97	9,92	22,33	31,6
3	2,35	3,18	4,54	5,84	10,22	12,9
4	2,13	2,78	3,75	4,60	7,17	8,61
5	2,01	2,57	3,37	4,03	5,89	6,86
6	1,94	2,45	3,14	3,71	5,21	5,96
7	1,89	2,36	3,00	3,50	4,79	5,40
8	1,86	2,31	2,90	3,36	4,50	5,04
9	1,83	2,26	2,82	3,25	4,30	4,78
10	1,81	2,23	2,76	3,17	4,14	4,59
11	1,80	2,20	2,72	3,11	4,03	4,44
12	1,78	2,18	2,68	3,05	3,93	4,32
13	1,77	2,16	2,65	3,01	3,85	4,22
14	1,76	2,14	2,62	2,98	3,79	4,14
15	1,75	2,13	2,60	2,95	3,73	4,07
16	1,75	2,12	2,58	2,92	3,69	4,01
17	1,74	2,11	2,57	2,90	3,65	3,95
18	1,73	2,10	2,55	2,88	3,61	3,92
19	1,73	2,09	2,54	2,86	3,58	3,88
20	1,73	2,09	2,53	2,85	3,55	3,85
21	1,72	2,08	2,52	2,83	3,53	3,82
22	1,72	2,07	2,51	2,82	3,51	3,79
23	1,71	2,07	2,50	2,81	3,49	3,77
24	1,71	2,06	2,49	2,80	3,47	3,74
25	1,71	2,06	2,49	2,79	3,45	3,72
26	1,71	2,06	2,48	2,78	3,44	3,71
27	1,71	2,05	2,47	2,77	3,42	3,69
28	1,70	2,05	2,46	2,76	3,40	3,66
29	1,70	2,05	2,46	2,76	3,40	3,66
30	1,70	2,04	2,46	2,75	3,39	3,65
40	1,68	2,02	2,42	2,70	3,31	3,55
47	1,68	2,01	2,41	2,68	3,27	3,51
48	1,68	2,01	2,40	2,68	3,27	3,50
60	1,67	2,00	2,39	2,66	3,23	3,46
120	1,66	1,98	2,36	2,62	3,17	3,37
∞	1,64	1,96	2,33	2,58	3,09	3,29